
Control de calidad para el análisis de datos de secuenciación generados en Illumina MiSeq™



Laboratorio de genómica y biología molecular

CNRIMA

Inciensa

Mayo, 2026


Bases del análisis de WGS



Para NGS se empieza con un genoma (libro completo), se descompone en millones de pedazos (sequence reads) y se trata de volver a construir utilizando algoritmos matemáticos.

Control de calidad


QC





Control de calidad de la corrida de secuenciación en Illumina MiSeqTM y MiniSeqTM

Viewing Run Metrics on the Sequencing Screen



Analysis | Imaging | Summary | Tile Status | TruSeq Controls | Indexing

Run Summary

Level	Yield Total (G)	Projected Total Yield (G)	Yield Perfect (G)	Yield <= 3 errors (G)	Aligned (%)	% Perfect (Num Cycles)	% <= 3 errors (Num Cycles)	Error Rate (%)	Intensity Cycle 1	% Intensity Cycle 20	% >= Q30
Read 1	3.5	3.5	0.0	0.0	0.00	0.0 [250]	0.0 [250]	0.00	187	134.0	94.2
Read 2 (I)	0.1	0.1	0.0	0.0	0.00	0.0 [7]	0.0 [7]	0.00	724	0.0	98.4
Read 3 (I)	0.1	0.1	0.0	0.0	0.00	0.0 [7]	0.0 [7]	0.00	449	0.0	97.6
Read 4	3.5	3.5	0.0	0.0	0.00	0.0 [250]	0.0 [250]	0.00	57	101.7	94.2
Total	7.1	7.1	0.0	0.0	0.00	0.0	0.0	0.00	354	117.8	94.2

Read 1

Lane	Tile	Density (K/mm2)	Cluster PF (%)	Phas/Prephas (%)	Reads (M)	Reads PF (M)	% >= Q30	Yield (G)	Cycles Err Rated	Aligned (%)	Error Rate (%)	Error Rate 25 cycle (%)	Error Rate 75 cycle (%)	Error Rate 100 cycle (%)	Intensity Cycle 1	% Intensity Cycle 20
1	28	729 +/- 24	96.54 +/- 0.16	0.000 / 0.004	14.32	13.82	94.2	3.5	0	0.0 +/- 0.0	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00	187 +/- 13	134.0 +/- 1.5

Read 2 (I)

Lane	Tile	Density (K/mm2)	Cluster PF (%)	Phas/Prephas (%)	Reads (M)	Reads PF (M)	% >= Q30	Yield (G)	Cycles Err Rated	Aligned (%)	Error Rate (%)	Error Rate 25 cycle (%)	Error Rate 75 cycle (%)	Error Rate 100 cycle (%)	Intensity Cycle 1	% Intensity Cycle 20
1	28	729 +/- 24	96.54 +/- 0.16	0.000 / 0.000	14.32	13.82	98.4	0.1	0	0.0 +/- 0.0	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00	724 +/- 57	0.0 +/- 0.0


Read 3 (I)

Lane	Tile	Density (K/mm2)	Cluster PF (%)	Phas/Prephas (%)	Reads (M)	Reads PF (M)	% >= Q30	Yield (G)	Cycles Err Rated	Aligned (%)	Error Rate (%)	Error Rate 25 cycle (%)	Error Rate 75 cycle (%)	Error Rate 100 cycle (%)	Intensity Cycle 1	% Intensity Cycle 20
1	28	729 +/- 24	96.54 +/- 0.16	0.000 / 0.000	14.32	13.82	97.6	0.1	0	0.0 +/- 0.0	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00	449 +/- 21	0.0 +/- 0.0

Read 4

Lane	Tile	Density (K/mm2)	Cluster PF (%)	Phas/Prephas (%)	Reads (M)	Reads PF (M)	% >= Q30	Yield (G)	Cycles Err Rated	Aligned (%)	Error Rate (%)	Error Rate 25 cycle (%)	Error Rate 75 cycle (%)	Error Rate 100 cycle (%)	Intensity Cycle 1	% Intensity Cycle 20
1	28	729 +/- 24	96.54 +/- 0.16	0.017 / 0.045	14.32	13.82	91.7	3.5	0	0.0 +/- 0.0	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00	0.00 +/- 0.00	57 +/- 7	101.7 +/- 12.9


Figure 1. Screen-shot of SAV “Summary Tab” highlighting key run metrics to be reviewed (in blue circles).



- Pantalla de MiSeq Control software
- Sequencing analysis viewer (SAV) en escritorio
- Sequencing analysis viewer (SAV) en basespace

Monitoreo de la
corrida de
secuenciación en
MiSeq

Viewing Run Metrics on the Sequencing Screen




V2 Cycle 5-25
V3 Cycle 8-25

Cycle 26


Interrogación de bases

- Nucleótido-fluoróforo
- En cada ciclo de secuenciación se evalúa la intensidad de cada fluoróforo y se asigna un valor de calidad a cada lectura.
- El secuenciador reporta la base por posición y un valor de calidad en formato Phred.
- El formato Phred indica la probabilidad de que la base sea errónea



Calidad Phred


Phred quality scores are logarithmically linked to error probabilities



Phred Quality Score	Probability of incorrect base call	Base call accuracy
10	1 in 10	90%
20	1 in 100	99%
30	1 in 1000	99.9%
40	1 in 10,000	99.99%
50	1 in 100,000	99.999%
60	1 in 1,000,000	99.9999%

Q30

- Porcentaje de lecturas con 99.9 % de probabilidad de que la base asignada sea la correcta
- Posibilidad de equivocarse en el Base calling 1:1000





Quality scores^a

MiSeq Sequencing System

Read length	MiSeq Reagent Kit v2	MiSeq Reagent Kit v3
2 × 25 bp	> 90% bases higher than Q30	N/A
2 × 75 bp	N/A	> 85% bases higher than Q30
2 × 150 bp	> 80% bases higher than Q30	N/A
2 × 250 bp	> 75% bases higher than Q30	N/A
2 × 300 bp	N/A	> 70% bases higher than Q30


a. The percentage of bases > Q30 is averaged across the entire run.

Generación de clusters



Densidad de clusters (Cluster Density) (K/mm²)

Muestra el número de clusters por milímetro cuadrado en el experimento



- La sobrecarga de la biblioteca puede provocar la fusión de grupos y, por lo tanto, una mayor densidad y una disminución del % FP con una reducción de la puntuación de calidad (Q30)
- Una entrada de carga baja de la biblioteca puede resultar en una baja densidad de clústeres y un rendimiento de datos insuficiente

Cluster density guidelines for Illumina sequencing platforms using non patterned flow cells

Cluster density is an important factor in optimizing data quality and yield. The following table lists the recommended raw cluster densities for balanced libraries (such as PhiX):

Platform	Mode/Reagents	Optimal Raw Cluster Density
MiSeq	v2	1000 – 1200 K/mm ²
	v3	1200 – 1400 K/mm ²
MiniSeq	Mid and High Output	170 – 220 K/mm ²
NextSeq 500/550	Mid and High Output	170 – 220 K/mm ²




The iSeq 100, MiSeq i100 Series, NextSeq 1000/2000, NovaSeq 6000, and NovaSeq X Series systems utilize patterned flow cells. This results in a fixed cluster density, even if all nanowells are not occupied. In these systems, monitoring the Cluster Pass filter (%) is a better measure of potential cluster occupancy.



Clusters que superan el filtro (%) (Clusters passing filter)

- Porcentaje de clusters que superan el filtro de “castidad” de Illumina, que mide la calidad según la pureza de intensidad de la señal de la lectura para cada cluster.
- Este dato aparece tras el ciclo 25
- Sólo los clusters que pasan el filtro serán utilizados para la generación de datos

The importance of cluster density



Nonpatterned Flow Cell



Métricas de calidad Protocolos PulseNet

- Q30
- Cluster Density
- Clusters Passing Filter

LABORATORY STANDARD OPERATING PROCEDURE FOR WHOLE GENOME SEQUENCING ON MISEQ

Doc. No. PNL38

Ver. No. 04

Effective Date: 07/08/2024

Page 12 of 29

- 9.8.2. Record the primary run metrics on the workbook. Compare Q30, cluster density and clusters passing filter to PulseNet's recommended run metrics thresholds in Table 5.
- NOTE:** *If the run metrics do not meet the thresholds listed in Table 5, it is possible that some of the sequences may still pass the critical quality metrics outlined in PNQ07. Further analysis of the sequences is required to determine whether individual sequences are acceptable or need to be repeated.*

Kit Chemistry	Q30 (%)	Cluster Density ² (K/mm ²)	Clusters Passing Filter (%)
v3, 500 cycle ¹	≥ 70	1200-1400	~ 80 or higher
v2, 500 cycle	≥ 75	800-1200	
v2, 300 cycle	≥ 80	800-1200	
Nano, v2 300 cycle	≥ 80	800-1200	
Nano, v2 500 cycle	≥ 75	800-1200	
Micro, v2 300 cycle	≥ 80	800-1200	

Table 5. Run metric thresholds for sequencing chemistries recommended by PulseNet.

¹Kit standard is 600 cycles but PulseNet recommends sequencing at 500 cycles for better quality.


²Illumina recommendation 600-1200 K/mm². For a full run with optimized loading concentration, PulseNet recommendation is 800-1200 K/mm².

Nuestros
resultados

Archivos FASTQ


Archivos Fastq

A. Library Preparation




NGS library is prepared by fragmenting a gDNA sample and ligating specialized adapters to both fragment ends.

B. Cluster Amplification




Library is loaded into a flow cell and the fragments are hybridized to the flow cell surface. Each bound fragment is amplified into a clonal cluster through bridge amplification.

C. Sequencing



Sequencing reagents, including fluorescently labeled nucleotides, are added and the first base is incorporated. The flow cell is imaged and the emission from each cluster is recorded. The emission wavelength and intensity are used to identify the base. This cycle is repeated "n" times to create a read length of "n" bases.

D. Alignment and Data Analysis




Reads are aligned to a reference sequence with bioinformatics software. After alignment, differences between the reference genome and the newly sequenced reads can be identified.

Figure 3: Next-Generation Sequencing Chemistry Overview—Illumina NGS includes four steps: (A) library preparation, (B) cluster generation, (C) sequencing, and (D) alignment and data analysis.


AAGGTTTATACCTTCCCAGGTAACAAACCAACCAACTTTCGATCTCTTGTAGATCTGTTCTCTAAACGAACTTTAAAATCTGTGTGGCTGTCACTCGGCTGCATGCTTAGTGCACTCACGCAGTATAATTAATAA
CTAATTACTGTCGTTGACAGGACACGAGTAACTCGTCTATCTTCTGCAGGCTGCTTACGGTTTCGTCCGTGTTGCAGCCGATCATCAGCACATCTAGGTTTTGTCCGGGT


Una “read” de
250
nucleótidos



AAGGTTTATACCTTCCCAGGTAACAAACCAACCAACTTTCGATCTCTTGTAGATCTGTTCTCTAAACGAACTTTAAAATCTGTGTGGCTGTCACTCGGCTGCATGCTTAGTGCACTCACGCAGTATAATTAATAACTAATTACTGTCGTTGACAGGACACGAGTAACTCGTCTATCTTCTGCAGGCTGCTTACGGTTTCGTCCGTGTTGCAGCCGATCATCAGC
ACATCTAGGTTTTGTCCGGGT

Un par de reads.... (1770)





1770 X 100

Archivo FASTQ

- Archivo de salida del secuenciador
- Archivo de texto plano
- Contienen para cada fragmento de ADN secuenciado la siguiente información:
 - Identificación
 - Ubicación en la celda de flujo
 - Secuencia de nucleótidos
 - Valores de calidad Phred

Línea 1 —	@SEQ_ID
Línea 2 —	GATTGGA ...
Línea 3 —	+
Línea 4 —	!""(((...

Anatomía de un Archivo FASTQ

```
@M07450:60:00000000-K8492:1:1101:17678:2002 1:N:0:23
CGCTAGCCCTTGTCTGTGTGGTGTATCACGCTCTGTCTTAGCGCCAAGTCTGTTTGCTTTCGCACTCTCGCTCAATAATTTCAATTCGAGTGGCGTCACTTCTCATACGCTTGAATCGTCTCATGTTTGACTTCACTC
+
>A1111CB1BC1BBEAE1FA0BBBAGE32DEEGF012FG2DG?ECAA/BAF1DE1B1GGFBAA/AEGF1>/>F/FFGB1FGHH2FDEF0/0B//CEE?//2BGDGF0D0EFA1>GHAF0?D>GDG2><1D1B12@FC
M07450:60:00000000-K8492:1:1101:11755:2017 1:N:0:23
CATTTAAGAGCTCTATCCATCCATTGATCTGAAATTGCTAACAGGAAATGAAATATCAGTTTCCAAGTTCTGGAATTGATGTCGCCATCTATTTTGATGACCATATGCCAGATAAGCTATCTTGCAAAGAAATATTCTC
+
AAAAAFB111>>GGG1FFGFGGCBAG11DDGGB3AFHFHGGF1AAAC0GG11AGGGHHGGHHH2A1/BFEGFH11FGF1GFHH/EECFHHGGHHHFFAGFBE11GFGBGFF1BF1FDEGHGHHHBB11@0FACGFHDFHC
M07450:60:00000000-K8492:1:1101:15577:2024 1:N:0:23
GATCTTATCCACGCTACGCACGGGAACCACTTCGGCGGCGGTACCTGTATGAAATTTTCATCGCCAGATAGAGTGCTTCGGCGGAGATGTTGGCTTCGCGCACTTCATAACCCATGTCGCGTGCTAGCGTCATGATCGAA
+
AABABFFFFD5F?EGFEFEAE2EE22AFACGHC2A0E0>>1?FG3GCEDEFBEBGEHHGH3/>EE/0BBG33FGDGF?D///@/?DGH1AGHH0->--<@CHGHFFHFFH.CGFGE?--;A00;-CDCF00;9..;
M07450:60:00000000-K8492:1:1101:17255:2027 1:N:0:23
GAATGTTACCGGGCGAGAAAAATCGTTCGTTAGCGGCGCAAGATGCGTTTGCGCGGCCCAATCCAGATCATGTCCATTACATGGATCGCAGTAAGTTTCTTGGTGGTATCTGCAGTTAGAGGTGCGGAACCATATGCG
+
AAAAAFF3DDA?EAAAAEEGFF/FGGGGGGGGHGE?A/EECEEGBG/EEC/FB/EGGGFHBEGHHFHC1>2B>DGGFGH20<FCCGEGCBFH1@FGGGDFDF?AFFGFHBDGBGFH1<CGC?@-.CCCHCBHGBE
M07450:60:00000000-K8492:1:1101:19691:2036 1:N:0:23
CACTGTAGTGGCTGATATTGATCGCCAAACGGCGAAAATGGGCGGTAAAATGCCTGTTTTCCTACTGGCATAATTGATAACACGCTTGCTCAATGATCCAGTTGCCTATCGGTAAAATTTGTCCTGTTTCTCTGCGA
+
1>AAAFBFBCC?FF11BAFGFGH0EEEFHGGG///DFC0/////>>B2BBDFFHFGHGHG0E2FEBCA<EGFDE22GHHF?CGGAG>FGHH21DB1<GGBB1<FHD1/AA/FBFFGF1111>D=GHHHHDGC1--
M07450:60:00000000-K8492:1:1101:19168:2038 1:N:0:23
ACTTTATCCACATCTTGATGATAGGCTCAAAACGAGGGTGTCTTTTGATGTCTTTCTCCAGACACATTGCAGCTGTAGGGTTGGCAATCGTTTGCTTCTCTTGGCAAAAAATTCGGAAGGAATTTTCAAAGC
+
AAA?A3DD3DBF1AFF311FBAF13BBF11FGF1FC0E0AA0AFEEGHHF1BDEFGGHHGHGH111/B0A12FG11FFHBB1DBFCGE@CFCFFA>GF?1BBDHFFHGG0B@00///B1GF//>///00@FG2G2221@
M07450:60:00000000-K8492:1:1101:17161:2043 1:N:0:23
GAGCT
+
A?AAA
M074
```

@M07450:60:000000000-K8492:1:1101:11755:2017 1:N:0:23

CATTTAAGAGCTCTATCCATCCATTGATCTGAAATTGCTAACAGGAAATGAAAATATCAGTTTCCAAGTTCTGGAATTGATGTCGCCATCTATTTTGATGACCATATGCCAGATAAGCTATCTTGCAAAGAA

+

AAAAAFB111>>GGG1FFGFGGCBAG11DDGGB3AFHFHGGF1AAAC0GG11AGGGHHGGHHH2A1/BFEGFH11FGF1GFHH/EECFHHGGHHHFFAGFBE11GFGBGFF1BF1FDEGHGHHHBB11@0FA

➡ @M07450:60:000000000-K8492:1:1101:11755:2017 1:N:0:23

Coordenadas de la celda de flujo para identificar esta secuencia de las demás

➡ CATTTAAGAGCTCTATCCATCCATTGATCTGAAATTGCTAACAGGAAATGAAAAT

Secuencia de nucleótidos leída para ese fragmento

➡ +

Signo +: separador


➡ AAAAAFB111>>GGG1FFGFGGCBAG11DDGGB3AFHFHGGF1AAAC0GG11AGG

Indica valores de calidad Phred correspondientes para cada uno de los nucleótidos de la línea 2

Valores Phred



Phred quality scores are logarithmically linked to error probabilities



Phred Quality Score	Probability of incorrect base call	Base call accuracy
10	1 in 10	90%
20	1 in 100	99%
30	1 in 1000	99.9%
40	1 in 10,000	99.99%
50	1 in 100,000	99.999%
60	1 in 1,000,000	99.9999%

Archivo Fastq





```
@M07450:60:000000000-K8492:1:1101:11755:2017 1:N:0:23
CATTAAAGAGCTCTATCCATCCATTGATCTGAAATTGCTAACAGGAAATGAAAT.
+
AAAAAFB111>>GGG1FFGFGGCBAG11DDGGB3AFHFFHGGF1AAAC0GG11AGG
```


Caracteres ASCII imprimibles

32	espacio	64	@	96	`
33	!	65	A	97	a
34	"	66	B	98	b
35	#	67	C	99	c
36	\$	68	D	100	d
37	%	69	E	101	e
38	&	70	F	102	f
39	'	71	G	103	g
40	(	72	H	104	h
41	)	73	I	105	i
42	*	74	J	106	j
43	+	75	K	107	k
44	,	76	L	108	l
45	-	77	M	109	m
46	.	78	N	110	n
47	/	79	O	111	o
48	0	80	P	112	p
49	1	81	Q	113	q
50	2	82	R	114	r
51	3	83	S	115	s
52	4	84	T	116	t
53	5	85	U	117	u
54	6	86	V	118	v
55	7	87	W	119	w
56	8	88	X	120	x
57	9	89	Y	121	y
58	:	90	Z	122	z
59	;	91	[	123	{
60	<	92	\	124	
61	=	93	]	125	}
62	>	94	^	126	~
63	?	95	_		

Valor Phred en archivos Fastq



Ejemplo



Línea 1	Identificador	@M07450...		
Línea 2	Secuencia	G	G	A
Línea 3	Separador	+		
Línea 4	Phred en ASCII	+	:	D
Valor Phred	NO en FASTQ	10	25	35


Análisis de calidad de las secuencias

FastQC

Cobertura


Profundidad

Longitud



Análisis de calidad de las secuencias

FastQC brinda un reporte de QC que permite detectar problemas que se originan en el secuenciador o con el material inicial de biblioteca




✓ Pass

! Warning

✗ Failure


Podemos
usar la
interfaz
gráfica o la
línea de
comandos

Aplicación interactiva



- Análisis inmediato de pequeñas cantidades de archivos FastQ

Análisis no interactivo



- Integrar a pipeline de análisis
- Procesar mayor cantidad de archivos FastQ
- Reporte se brinda en HTML

Basic Statistics

FastQC

File Help


751321_1.fastq.gz 751321_2.fastq.gz

		Basic sequence stats	
		Measure	Value
	Basic Statistics	Filename	Nombre del archivo
	Per base sequence quality	File type	Tipo del archivo
	Per tile sequence quality	Encoding	Formato de los valores de calidad
	Per sequence quality scores	Total Sequences	Número total de secuencias
	Per base sequence content	Sequences flagged as poor quality	Secuencias marcadas de baja calidad
	Per sequence GC content	Sequence length	Tamaño de la secuencia más corta y más larga
	Per base N content	%GC	% de GC de todas las bases en todas las secuencias
	Sequence Length Distribution		
	Sequence Duplication Levels		
	Overrepresented sequences		
	Adapter Content		




No se da señal de advertencia o error

Per Base Sequence Quality



- ! Cuando el cuartil menor de cualquier base es menor de 10 o si la mediana de cualquier base es menor de 25
- ✗ El cuartil menor de cualquier base es menor de 5 o si la mediana de cualquier base es menor de 20

Per Base Sequence Quality




Figures 6 & 7. Example of sequences with passing per base sequence quality (left) and non-passing per base sequence quality (right).



El cuartil menor de cualquier base es menor de 5 o si la mediana de cualquier base es menor de 20


Per Tile Sequence Quality



Las razones para ver advertencias o errores en esta gráfica podrían ser problemas transitorios, como burbujas que atraviesan la celda de flujo, o podrían ser problemas más permanentes, como manchas en la celda de flujo o escombros dentro del carril de celda de flujo.



- ! Si cualquier mosaico muestra una puntuación media de Phred de más de 2 menos que la media de esa base en todos los mosaicos.
- ✗ Si algún mosaico muestra una puntuación media de Phred de más de 5 menos que la media de esa base en todos los mosaicos.

Per Sequence Quality Scores




- ⚠ Si calidad promedio con mayor frecuencia es menor a 27 (indica tasa de error de 0.2%)
- ❌ Si calidad promedio con mayor frecuencia es menor a 20 (indica tasa de error de 1%)

Per Sequence Quality Scores



Figures 8 & 9. Examples of sequences with passing quality score distribution over all sequences (left,) and non-passing quality score distribution over all sequences (right).



Sequence Length Distribution



La mayoría de las secuencias deberían estar en la mayor longitud. Por ejemplo la línea roja debería mantenerse plana hasta aproximadamente 240 para una corrida de 500 ciclos.


- ⚠ Si todas las secuencias no son del mismo tamaño
- ✖ Si alguna de las secuencias tiene una longitud de o

Sequence Length Distribution




Figures 12 & 13. Examples of the “Sequence Length Distribution” graphs: A sequence with ideal distribution of sequence length (left), and the graph for a sequence with less than ideal sequence length distribution (right).

Per Base Sequence Content




- ! Si la diferencia entre A y T, o G y C es mayor de 10% en cualquier posición
- ✗ Si la diferencia entre A y T, o G y C es mayor de 20% en cualquier posición

Per Base N Content



- ! Si cualquier posición muestra un contenido de N mayor a 5%
- ✗ Si cualquier posición muestra un contenido de N mayor a 20%

Per Base N Content




Figures 10 & 11. Example of “Per base N content” graph for a sequence with ideal N content across all bases (left) and an example of a graph with a higher percentage of N content (right).

Overrepresented Sequences

Overrepresented sequences			
Sequence	Count	Percentage	Possible Source
CCCTAGCATTGTTCACTGTACACTCGATCGTACTCCGCGTGGCC...	257	0,145	No Hit
NN	250	0,141	No Hit
GACCTACACAGGTGCCATCAAATTGGATGACAAAGTCCAAATT...	246	0,139	No Hit
CTCCAAGGGTGTTCACTTTGTTTGCAACTTGCTGTTGTTGTTGT...	233	0,131	No Hit
ATCGTACTCCGCGTGGCCTCGGTGAAAATGTGGTGGCTCTTTCA...	228	0,129	No Hit
GGGTTACGTGAAGGAATTCTTTACCACGCCTATTTGTGGCCT...	209	0,118	No Hit
CGTTTACTCTCGTGTTAAAAATCTGAATTCTTCTAGAGTTCCTGA...	188	0,106	No Hit
GGTAATTACCAAGTGGTCACTATAAACATATAACTTCTAAAGA...	179	0,101	No Hit
GTTCTATACCTTGTAGTGTTTGCTTAGTGGTTTAGATTCTTTAGA...	178	0,1	No Hit


- ⚠ Si se encuentra alguna secuencia que represente más del 0.1% del total
- ✖ Si se encuentra alguna secuencia que represente más del 1% del total

Adapter Content



- ! Si se encuentra alguna secuencia que represente más del 5% de todas las lecturas
- ✗ Si se encuentra alguna secuencia que represente más del 10% de todas las lecturas




Per Sequence GC Content



- ! si la suma de las desviaciones de la distribución normal representa más del 15 % de las lecturas.
- ✗ si la suma de las desviaciones de la distribución normal representa más del 30 % de las lecturas.


Per Sequence GC Content

Detección de contaminación



Kraken: *Salm* 78.0%, *Campylobacter* 10.4%
(GC% shoulder, around 36)

Cobertura



Cálculo de cobertura con FastQC





Figure 5. Basic Statistics tab in FastQC

Cobertura



Métricas de calidad Protocolos PulseNet

PULSENET STANDARD OPERATING PROCEDURE FOR ILLUMINA DATA QUALITY CONTROL			
Doc. No. PNQ07	Ver. No. 08	Effective Date: 3/23/2020	Page 18 of 18

Appendix PNQ07-1. Requirements for Critical Quality Metrics for PulseNet Organisms for Routine Sequence Submissions.

Organism	Average denovo coverage	Average quality (Q score)	Assembly length (MB)	Secondary species abundance	% core present ¹
<i>Listeria monocytogenes</i>	≥ 20x	≥ 30	2.8-3.2	≤ 1.0	≥ 95
<i>E. coli</i> (most serotypes)	≥ 40x	≥ 30	4.9-6.0	≤ 1.0	≥ 85
<i>Shigella spp./Rare E. coli</i>	≥ 40x	≥ 30	4.2-4.9	≤ 1.0	≥ 85
<i>Salmonella spp.</i>	≥ 30x	≥ 30	4.4-5.7	≤ 1.0	≥ 85
<i>Campylobacter spp.</i>	≥ 20x	≥ 30	1.4-2.2	≤ 1.0	≥ 85 ²
<i>Vibrio cholerae</i>	≥ 40x	≥ 30	3.8-4.3	≤ 1.0	NA
<i>Vibrio parahaemolyticus</i>	≥ 40x	≥ 30	4.9-5.5	≤ 1.0	NA
<i>Vibrio vulnificus</i>	≥ 40x	≥ 30	4.7-5.3	≤ 1.0	NA

Table 3. Requirements for critical quality metrics for PulseNet organisms

Recursos

- [Does my sequencing run look good? - Support Illumina](#)
- [MiSeq: Does My Run Look Good? - Support Illumina](#)
- [Sequencing Analysis Viewer Software Guide \(15066069\)](#)
- <https://github.com/s-andrews/FastQC>
- <https://www.bioinformatics.babraham.ac.uk/projects/fastqc/Help/3%20Analysis%20Modules/>