

---

# Herramientas para análisis bioinformático de bacterias

## Plataforma Terra Bio

Dra. Estela Cordero Laurent  
Laboratorio de genómica y biología molecular  
Inciensa

Junio, 2026

# Fuentes de información

- Ambrosio, Frank. Introduction to the Terra.bio Platform. Taller Subregional de Secuenciación y Análisis Bioinformáticos para Patógenos Bacterianos 2024. Tegucigalpa.
- Ambrosio, Frank. Bacterial Genomic Characterization Analysis. Taller Subregional de Secuenciación y Análisis Bioinformáticos para Patógenos Bacterianos 2024. Tegucigalpa.
- Ambrosio, Frank. Interpretation of Genomic Characterization Results. Taller Subregional de Secuenciación y Análisis Bioinformáticos para Patógenos Bacterianos 2024. Tegucigalpa.
- Ambrosio, Frank. Introduction to Phylogenetics for Pathogen Surveillance and Outbreak Investigations. Taller Subregional de Secuenciación y Análisis Bioinformáticos para Patógenos Bacterianos 2024. Tegucigalpa.
- Avilez, Soany. Módulo 6. Introducción y aplicación de la plataforma Terra Bio. Taller Regional de Entrenadores en Secuenciación de Patógenos Bacterianos Entéricos 2025. Ciudad de Panamá.
- Lara, Adolfo. Módulo 6 – Crear hoja de metadatos y subir datos. Taller Regional de Entrenadores en Secuenciación de Patógenos Bacterianos Entéricos 2025. Ciudad de Panamá.
- Lara, Adolfo. Módulo 6 –Ejercicio: TheiaProk. Taller Regional de Entrenadores en Secuenciación de Patógenos Bacterianos Entéricos 2025. Ciudad de Panamá.
- Lara, Adolfo. Trasfondo biológico deTheiaProk. Taller Regional de Entrenadores en Secuenciación de Patógenos Bacterianos Entéricos 2025. Ciudad de Panamá.




# Plataforma Terra



Terra es una **aplicación web bioinformática**



- Se ejecuta en un navegador de Internet, apunta y haz clic
- Carga y organiza datos de secuencias
- Analiza los datos con flujos de trabajo bioinformáticos
- Acceda, descarga y comparte resultados

# Iniciar sesión en Terra





# Acceso a los espacios de trabajo



# Ingresa a su espacio de trabajo

 WORKSPACES

## Workspaces +

Dedicated spaces for you and your collaborators to access and analyze data together. [Learn more about workspaces.](#)

▼ Recently Viewed

APHL\_PAN\_ONTRegional\_2025\_Cordero  
Viewed 19 mar 2026, 17:10

Tags▼Access levels▼Billing project▼

MY WORKSPACES (1)FEATURED (84)PUBLIC (324)

| Name                                                                                                                                                                                 | Last Modified ↑ | Created By                | Access Level                                                                                                                                                                  |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------|---------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| ★ <a href="#">APHL_PAN_ONTRegional_2025_Cordero</a><br>Este espacio de trabajo está destinado al análisis bacteriano mediante flujos de trabajo de <a href="#">Terra</a> y [WDL ...] | 18 mar 2026     | adolfo.lara.sci@gmail.com | Owner   |

Espacio dedicado para **organizar datos, acceder a flujos de trabajo y realizar análisis bioinformáticos.**

# Carga de secuencias y metadatos en el espacio de trabajo Terra

# Carga de lecturas y metadatos en Terra

The screenshot displays the Terra WORKSPACES interface. The top navigation bar is green and contains the Terra logo, the word "WORKSPACES", and the breadcrumb "Workspaces > theiagen-training-workspaces/APHL\_GHANA\_Training\_Doughty > Data". On the right of the top bar are links for "COVID-19 Data & Tools" and a notification bell with a "2" badge. Below the top bar is a secondary navigation bar with tabs: "DASHBOARD", "DATOS" (highlighted in green), "WORKFLOWS", and "JOB HISTORY". A blue arrow points to the "DATOS" tab. Below the tabs is a large light blue area with the text "Select a data type from the navigation panel on the left". On the left side, there is a navigation panel with three main sections: "TABLES", "REFERENCE DATA", and "OTHER DATA". The "TABLES" section is expanded and contains a search bar "Search all tables" and a list of tables: "illumina\_pe\_sp..." (20), "illumina\_pe\_spe..." (8), "ont\_specimen" (10), and "ont\_specimen\_set" (1). Each table entry has an information icon. The "REFERENCE DATA" section shows "No references have been added." and a link "Add reference data". The "OTHER DATA" section contains "Workspace Data". A blue arrow points to the "+ IMPORTAR DATOS" button located above the "TABLES" section. On the far right, a vertical sidebar shows a "Rate: \$0.00 per hour" and a lightning bolt icon.

# Carga de lecturas y metadatos en Terra

The screenshot displays the Terra Data interface. The top navigation bar is green and contains the Terra logo, the word "WORKSPACES", and the current workspace path: "Workspaces > theiagen-training-workspaces/APHL\_GHANA\_Training\_Doughty > Data". On the right of the top bar are links for "COVID-19 Data & Tools" and a notification bell with a "2" badge.

Below the top bar is a secondary navigation bar with tabs: "DASHBOARD", "DATOS" (which is highlighted), "ANALYSES", "WORKFLOWS", and "JOB HISTORY".

The main content area of the "DATOS" tab is light gray and contains the text: "Select a data type from the navigation panel on the left".

On the left side, there is a vertical navigation panel. At the top of this panel is a button labeled "+ IMPORTAR DATOS". A blue arrow points to this button's dropdown menu, which is open and shows three options: "CARGAR TSV", "ABRIR EL CARGADOR DE DATOS", and "ANADIR DATOS DE REFERENCIA".

Below the dropdown menu, the navigation panel lists several data types with icons, names, and counts in parentheses, each followed by an information icon (i):

- illumina\_pe\_sp... (20)
- illumina\_pe\_spe... (8)
- ont\_specimen (10)
- ont\_specimen\_set (1)

Below these items are three expandable sections:

- REFERENCE DATA** (with a downward arrow icon). The content below it says: "No references have been added." and "Add reference data".
- OTHER DATA** (with a downward arrow icon).
- Workspace Data** (with a document icon).

On the far right of the interface, there is a vertical sidebar. It contains a "Rate: \$0.00 per hour" label and a cloud icon with a lightning bolt.

# Carga de lecturas y metadatos en Terra

The screenshot displays the Terra Data Uploader interface. At the top, a green header bar contains the Terra logo, the word "BETA", and the text "DATA UPLOADER". On the right side of the header is a notification bell icon with a "2" badge. Below the header, a grey bar shows the workspace name "thelagen-training-workspaces" and "APHL\_GHANA\_Training\_D". A modal window titled "CREAR UNA NUEVA COLECCIÓN" is centered on the screen. It contains a text input field labeled "NOMBRE DE LA COLECCIÓN\*" with the value "CRIN\_M07450\_20260316". A blue arrow points to this input field. Below the input field are two buttons: "CANCELAR" and "CREAR COLECCIÓN". To the right of the modal, a "Change" button is visible. At the bottom right of the interface is a "NEXT >" button. A descriptive text at the bottom states: "CADA COLECCIÓN REPRESENTA UN GRUPO DE ARCHIVOS CON UN ÚNICO ARCHIVO DE METADATOS QUE DESCRIBE LA ESTRUCTURA DE LA TABLA. PUEDES CREAR UNA NUEVA COLECCIÓN O AÑADIR ARCHIVOS A UNA YA EXISTENTE." Below this text is a link that says "+ CREAR UNA NUEVA COLECCIÓN".

DATA UPLOADER

ESPACIO DE TRABAJO thelagen-training-workspaces APHL\_GHANA\_Training\_D

Change

NEXT >

CREAR UNA NUEVA COLECCIÓN

NOMBRE DE LA COLECCIÓN\*

CRIN\_M07450\_20260316

CANCELAR CREAR COLECCIÓN

CADA COLECCIÓN REPRESENTA UN GRUPO DE ARCHIVOS CON UN ÚNICO ARCHIVO DE METADATOS QUE DESCRIBE LA ESTRUCTURA DE LA TABLA. PUEDES CREAR UNA NUEVA COLECCIÓN O AÑADIR ARCHIVOS A UNA YA EXISTENTE.

+ CREAR UNA NUEVA COLECCIÓN

# Carga de lecturas y metadatos en Terra

 BETA  
**DATA UPLOADER**



 **ESPACIO DE TRABAJO**

theiagen-training-workspaces  
APHL\_GHANA\_Training\_Doughty

**CAMBIAR**

 **COLECCIÓN**

Genomic\_Epi\_Dataset

**CAMBIAR**

 **CARGAR TUS ARCHIVOS DE DATOS**

**NEXT >**

CARGUE LOS ARCHIVOS QUE DESEA ASOCIAR A ESTA COLECCIÓN ARRASTRÁNDOLOS A LA CASILLA INFERIOR O HACIENDO CLIC EN EL BOTÓN CARGAR.

PUEDES SUBIR TANTOS ARCHIVOS COMO DESEES, PERO CADA NOMBRE DE ARCHIVO DEBE SER ÚNICO.

Genomic\_Epi\_Dataset/




 **CARGAR**  Delete

| <input type="checkbox"/> NOMBRE           | TAMAÑO | MODIFICADO POR ÚLTIMA VEZ |
|-------------------------------------------|--------|---------------------------|
| TODAVÍA NO HA SIDO CARGADO NINGÚN ARCHIVO |        |                           |



# Carga de lecturas y metadatos en Terra



# Carga de lecturas y metadatos en Terra

The screenshot displays the Terra Data Uploader interface. At the top, a green header contains the Terra logo, the word "BETA", and the text "DATA UPLOADER". A notification bell icon with a "2" badge is in the top right corner. The main content area is divided into two sections: "ESPACIO DE TRABAJO" (Workspace) and "COLECCIÓN" (Collection). The workspace section shows "theiagen-training-workspaces" and "APHL\_GHANA\_Training\_D". The collection section shows "Genomic\_Epi\_Dataset". A modal dialog titled "CARGA EN PROGRESO..." (Uploading in progress...) is centered on the screen. It displays "CARGANDO 1 DE 40 ARCHIVOS" (Uploading 1 of 40 files), the file name "19\_S19\_L001\_R1\_001.fastq.gz", and the size "33.3 MB". A red "CANCELAR CARGA" (Cancel upload) button is at the bottom of the modal. Below the modal, there is a "NEXT >" button. At the bottom of the page, there is a section for uploading files to the "Genomic\_Epi\_Dataset/" collection. It includes a "CARGAR" (Upload) button and a "Delete" button. Below this, there is a table with columns for "NOMBRE" (Name), "TAMAÑO" (Size), and "MODIFICADO POR ÚLTIMA VEZ" (Last modified). The table currently shows "TODAVÍA NO HA SIDO CARGADO NINGÚN ARCHIVO" (No files have been uploaded yet).

**ESPACIO DE TRABAJO** theiagen-training-workspaces APHL\_GHANA\_Training\_D **CAMBIAR**

**COLECCIÓN** Genomic\_Epi\_Dataset **CAMBIAR**

**CARGA EN PROGRESO...**

CARGANDO 1 DE 40 ARCHIVOS

CARGANDO:  
19\_S19\_L001\_R1\_001.fastq.gz

TAMAÑO:  
33.3 MB

**CANCELAR CARGA**

**Genomic\_Epi\_Dataset/** **CARGAR** Delete

| NOMBRE                                    | TAMAÑO | MODIFICADO POR ÚLTIMA VEZ |
|-------------------------------------------|--------|---------------------------|
| TODAVÍA NO HA SIDO CARGADO NINGÚN ARCHIVO |        |                           |

# Carga de lecturas y metadatos en Terra

 BETA  
**DATA UPLOADER**



 ESPACIO DE TRABAJO

theiagen-training-workspaces  
APHL\_GHANA\_Training\_Doughty

CAMBIAR

 COLECCIÓN

Genomic\_Epi\_Dataset

CAMBIAR

 CARGAR TUS ARCHIVOS DE DATOS



SIGUIENTE >

CARGUE LOS ARCHIVOS QUE DESEA ASOCIAR A ESTA COLECCIÓN ARRASTRÁNDOLOS A LA CASILLA INFERIOR O HACIENDO CLIC EN EL BOTÓN CARGAR.

PUEDES SUBIR TANTOS ARCHIVOS COMO DESEES, PERO CADA NOMBRE DE ARCHIVO DEBE SER ÚNICO.

Genomic\_Epi\_Dataset/

 CARGAR  Delete

| <input type="checkbox"/> NOMBRE                                      | TAMAÑO | MODIFICADO POR ÚLTIMA VEZ |
|----------------------------------------------------------------------|--------|---------------------------|
| <input type="checkbox"/> <a href="#">13_S13_L001_R1_001.fastq.gz</a> | 41 MB  | Today                     |
| <input type="checkbox"/> <a href="#">13_S13_L001_R2_001.fastq.gz</a> | 46 MB  | Today                     |
| <input type="checkbox"/> <a href="#">15_S15_L001_R1_001.fastq.gz</a> | 32 MB  | Today                     |
| <input type="checkbox"/> <a href="#">15_S15_L001_R2_001.fastq.gz</a> | 37 MB  | Today                     |
| <input type="checkbox"/> <a href="#">17_S17_L001_R1_001.fastq.gz</a> | 37 MB  | Today                     |

# Carga de lecturas y metadatos en Terra

The screenshot shows the Terra Data Uploader interface. The top navigation bar is green with the Terra logo and 'BETA DATA UPLOADER'. The main content area has a sidebar with 'ESPACIO DE TRABAJO' (theiagen-training-workspaces APHL\_GHANA\_Training\_Doughty), 'COLECCIÓN' (Genomic\_Epi\_Dataset), and 'ARCHIVOS DE DATOS' (INCLUYE 40 ARCHIVOS). The main area contains instructions for uploading a tab-separated file describing table structures, with a list of requirements: any columns referencing files should include just the filenames, and the first column must contain unique identifiers for each row. Below this is a dashed box for dropping files, with the text 'and drop your metadata .tsv or .txt file here' and 'ARRASTRAR Y SOLTAR TU METADATA .TSV O ARCHIVO .TXT AQUI'. A Windows File Explorer window is overlaid on the right, showing the 'sc2-training-set-2022-06-23' folder. The file list shows 'illumina\_pe\_metadata.tsv' (TSV File) and 'read\_files' (File folder), both dated 25/05/2023 13:30. A large blue arrow points from the 'illumina\_pe\_metadata.tsv' file in the File Explorer to the drop zone in the Terra interface.

Terra BETA DATA UPLOADER

ESPACIO DE TRABAJO theiagen-training-workspaces APHL\_GHANA\_Training\_Doughty

COLECCIÓN Genomic\_Epi\_Dataset

ARCHIVOS DE DATOS INCLUYE 40 ARCHIVOS

Upload a tab-separated file describing your table structures.

- Any columns which reference files should include just the filenames, which will be used to look up the files in the workspace.
- The first column must contain the unique identifiers for each row. The name of the column must be `entity:sample_id`.

For example, if the first column is named `entity:sample_id`, a table named "sc2" will be created with the following structure:

and drop your metadata .tsv or .txt file here

ARRASTRAR Y SOLTAR TU METADATA .TSV O ARCHIVO .TXT AQUI

sc2-training-set-2022-06-23

New

Sort

Home

Emma - Personal

Desktop

Downloads

Documents


Pictures

Music

2 items

| Name                     | Date modified    | Type        |
|--------------------------|------------------|-------------|
| illumina_pe_metadata.tsv | 25/05/2023 13:30 | TSV File    |
| read_files               | 25/05/2023 13:30 | File folder |

# Carga de lecturas y metadatos en Terra



sc2-training-set-2022-06-23

New

sc2... > sc2... > Search sc2-training-set-2022-06-23

Home


Emma - Personal

Today

illumin...\_pe\_meta

read\_files

2 items



Autoguardado

bs\_fetch\_template\_manualupload\_transformar\_a\_TS

Archivo Inicio Insertar Dibujar Disposición de página Fórmulas Datos Revisar Vis

Cortar Copiar Copiar formato

Pegar

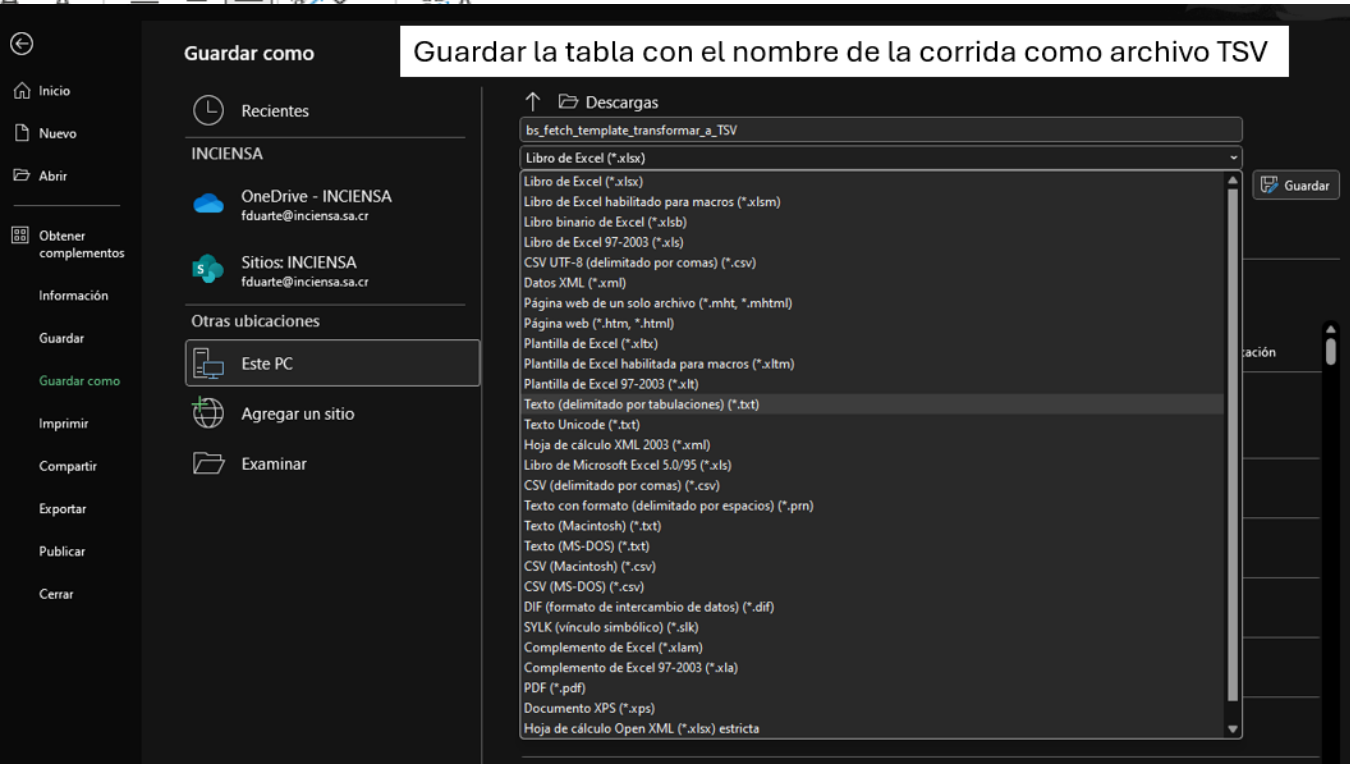
Portapapeles

Fuente

Aptos Narrow 11

C9

|   | A                       | B                               |
|---|-------------------------|---------------------------------|
| 1 | entity:2025_Listeria_id | read_1                          |
| 2 | 850849                  | 850849_S14_L001_R1_001.fastq.gz |
| 3 | 850855                  | 850855_S15_L001_R1_001.fastq.gz |
| 4 | 852393                  | 852393_S1_L001_R1_001.fastq.gz  |
| 5 | 852394                  | 852394_S2_L001_R1_001.fastq.gz  |
| 6 | 852395                  | 852395_S3_L001_R1_001.fastq.gz  |



Guardar como

Recientes

INCIENSA

OneDrive - INCIENSA  
fduarte@inciensa.sa.cr

Sitios: INCIENSA  
fduarte@inciensa.sa.cr

Otras ubicaciones

Este PC

Agregar un sitio

Examinar

Guardar la tabla con el nombre de la corrida como archivo TSV

bs\_fetch\_template\_transformar\_a\_TSV

Libro de Excel (\*.xlsx)

Libro de Excel (\*.xlsx)

Libro de Excel habilitado para macros (\*.xlsm)

Libro binario de Excel (\*.xlsb)

Libro de Excel 97-2003 (\*.xls)

CSV UTF-8 (delimitado por comas) (\*.csv)

Datos XML (\*.xml)

Página web de un solo archivo (\*.mht, \*.mhtml)

Página web (\*.htm, \*.html)

Plantilla de Excel (\*.xlt)

Plantilla de Excel habilitada para macros (\*.xltx)

Plantilla de Excel 97-2003 (\*.xlt)

Texto (delimitado por tabulaciones) (\*.txt)

Texto Unicode (\*.txt)

Hoja de cálculo XML 2003 (\*.xml)

Libro de Microsoft Excel 5.0/95 (\*.xls)

CSV (delimitado por comas) (\*.csv)

Texto con formato (delimitado por espacios) (\*.prn)

Texto (Macintosh) (\*.txt)

Texto (MS-DOS) (\*.txt)

CSV (Macintosh) (\*.csv)

CSV (MS-DOS) (\*.csv)

DIF (formato de intercambio de datos) (\*.dif)

SYLK (vínculo simbólico) (\*.slk)

Complemento de Excel (\*.xlam)

Complemento de Excel 97-2003 (\*.xla)

PDF (\*.pdf)

Documento XPS (\*.xps)

Hoja de cálculo Open XML (\*.xlsx) estricta

Guardar

# Carga de lecturas y metadatos en Terra

 BETA  
DATA UPLOADER

ESPACIO DE TRABAJO

theiagen-training-workspaces  
APHL\_GHANA\_Training\_Doughty

CAMBIAR

COLECCIÓN

Genomic\_Epi\_Dataset

CAMBIAR

ARCHIVOS DE DATOS

INCLUYE 40 ARCHIVOS

CAMBIAR

 CARGAR TUS ARCHIVOS DE METADATOS

ACTUALIZANDO TABLA: **illumina\_pe\_specimen** [RENOMBRAR TABLA](#)

 **CARGAR TABLA**

SI ESTA TABLA TE PARECE CORRECTA, HAZ CLIC EN EL BOTÓN DE LA DERECHA PARA ACTUALIZARLA EN TU ESPACIO DE TRABAJO.

| entity: illumina_pe_specimen... | ▲ read1 (updated)                           | ▲ read2 (updated)                           | ▲ run_id (updated) |
|---------------------------------|---------------------------------------------|---------------------------------------------|--------------------|
| Sample_01                       | <a href="#">13_S13_L001_R1_001.fastq.gz</a> | <a href="#">13_S13_L001_R2_001.fastq.gz</a> | training_data      |
| Sample_02                       | <a href="#">15_S15_L001_R1_001.fastq.gz</a> | <a href="#">15_S15_L001_R2_001.fastq.gz</a> | training_data      |
| Sample_03                       | <a href="#">17_S17_L001_R1_001.fastq.gz</a> | <a href="#">17_S17_L001_R2_001.fastq.gz</a> | training_data      |

# Carga de lecturas y metadatos en Terra

 BETA  
DATA UPLOADER



 2

|                       |                                                                         |         |
|-----------------------|-------------------------------------------------------------------------|---------|
| ⚙ ESPACIO DE TRABAJO  | theigen-training-workspaces<br>APHL_GHANA_Training_Doughty              | CAMBIAR |
| 📁 COLECCIÓN           | Genomic_Epi_Dataset                                                     | CAMBIAR |
| 📄 ARCHIVOS DE DATOS   | INCLUYE 40 ARCHIVOS                                                     | CAMBIAR |
| 📊 TABLAS DE METADATOS | TABLA ACTUALIZADA illumina_pe_specimen, AÑADIDAS O MODIFICADAS 20 FILAS | CAMBIAR |

¡LISTO!

⚙ VER LA TABLA illumina\_pe\_specimen EN EL ESPACIO DE TRABAJO

📄 CREAR UNA NUEVA TABLA EN LA COLECCIÓN genomic\_Epi\_Dataset

📁 EMPEZAR DE NUEVO CON OTRO ESPACIO DE TRABAJO O COLECCIÓN



# Pestaña de datos

Terra

BETA

WORKSPACES

Workspaces > theiagen-demos/TheiaCoV\_Training\_Demos > Data

COVID-19 Data & Tools

1

DASHBOARD

DATA

ANALYSES

WORKFLOWS

SUBMISSION HISTORY

SETTINGS

Import Data

TABLES

Search all tables

2020\_Enterococc... (3)

2020\_Enterococc... (1)

2025\_Listeria (5)

listeria\_ont\_demo (44)

listeria\_ont\_demo... (3)

salmonella\_ont\_p... (5)

salmonella\_ont\_p... (1)

REFERENCE DATA

No references have been added.

Add reference data

Edit

Settings

0 rows selected

Export

wd1

Advanced Search

Search

Rate: \$0.00 per hour

|  | 2025_Li... | read_1                                          | read_2                                          |
|--|------------|-------------------------------------------------|-------------------------------------------------|
|  | 850849     | <a href="#">850849_S14_L001_R1_001.fastq.gz</a> | <a href="#">850849_S14_L001_R2_001.fastq.gz</a> |
|  | 850855     | <a href="#">850855_S15_L001_R1_001.fastq.gz</a> | <a href="#">850855_S15_L001_R2_001.fastq.gz</a> |
|  | 852393     | <a href="#">852393_S1_L001_R1_001.fastq.gz</a>  | <a href="#">852393_S1_L001_R2_001.fastq.gz</a>  |
|  | 852394     | <a href="#">852394_S2_L001_R1_001.fastq.gz</a>  | <a href="#">852394_S2_L001_R2_001.fastq.gz</a>  |
|  | 852395     | <a href="#">852395_S3_L001_R1_001.fastq.gz</a>  | <a href="#">852395_S3_L001_R2_001.fastq.gz</a>  |

1 - 5 of 5

<<

<

1

>

>>

Items per page: 100



Terra

BETA

WORKSPACES

Workspaces > theiagen-cromwell/Terra\_Training > Data

DASHBOARD

DATOS

NOTEBOOKS

WORKFLOWS

JOB HISTORY

TABLES

+

clearlabs\_specimen (21)

clearlabs\_specimen\_set (9)

illumina\_specimen (5)

illumina\_specimen\_set (2)

ont\_specimen

ont\_specimen\_set (3)

REFERENCE DATA

+

OTHER DATA

Workspace Data

Files

DOWNLOAD ALL ROWS

COPY PAGE TO CLIPBOARD

0 rows selected


|                          | ont_specimen_id | number_N | go_lineage | reads                        |
|--------------------------|-----------------|----------|------------|------------------------------|
| <input type="checkbox"/> | Sample_01       | 953      | B.1.1.7    | <a href="#">Sample_01.gz</a> |
| <input type="checkbox"/> | Sample_02       | 29565    | None       | <a href="#">Sample_02.gz</a> |
| <input type="checkbox"/> | Sample_03       | 1682     | B.1.617.2  | <a href="#">Sample_03.gz</a> |
| <input type="checkbox"/> | Sample_04       | 28874    | None       | <a href="#">Sample_04.gz</a> |
| <input type="checkbox"/> | Sample_05       | 2795     | B.1.436    | <a href="#">Sample_05.gz</a> |
| <input type="checkbox"/> | Sample_06       | 29554    | None       | <a href="#">Sample_06.gz</a> |
| <input type="checkbox"/> | Sample_07       | 2817     | P.1        | <a href="#">Sample_07.gz</a> |
| <input type="checkbox"/> | Sample_08       | 28196    | None       | <a href="#">Sample_08.gz</a> |
| <input type="checkbox"/> | Sample_09       | 2624     | B.1        | <a href="#">Sample_09.gz</a> |
| <input type="checkbox"/> | Sample_10       | 2588     |            |                              |
| <input type="checkbox"/> | Sample_11       | 2493     |            |                              |

entidad

atributo

Los datos de una tabla de datos Terra pueden analizarse con un flujo de trabajo Terra

# Pestaña Flujos de trabajo



The screenshot shows the Terra Workspaces interface. At the top, a green header bar contains the Terra logo, the word "WORKSPACES", and a breadcrumb trail: "Workspaces > aphl-personal/APHL\_PAN\_ONTRegional\_2025\_Cordero > Workflows". Below this is a navigation bar with tabs: "DASHBOARD", "DATA", "ANALYSES", "WORKFLOWS" (highlighted in green), "HISTORY", and "SETTINGS". A large blue arrow points from the "WORKFLOWS" tab to the main content area. The main content area is titled "WORKFLOWS" and includes a search bar labeled "SEARCH WORKFLOWS", a "Sort By:" dropdown menu set to "Alphabetical", and two icons for grid and list views. Below these are several workflow cards. The first card is "Find a Workflow" with a plus icon. The second row contains four cards: "BaseSpace\_Fetch\_PHB", "kSNP4\_PHB", "SRA\_Fetch\_PHB", and "TheiaProk\_Illumina\_PE\_PHB". The fifth card, "TheiaProk\_ONT\_PHB", is partially visible below the first card of the second row. Each card displays the workflow name, version (e.g., "V. main" or "V. v4.0.0"), and source ("Source: Dockstore"). A blue arrow points to the "TheiaProk\_Illumina\_PE\_PHB" card.

WORKSPACES

Workspaces > aphl-personal/APHL\_PAN\_ONTRegional\_2025\_Cordero > Workflows

DASHBOARD DATA ANALYSES **WORKFLOWS** HISTORY SETTINGS

WORKFLOWS

SEARCH WORKFLOWS Sort By: Alphabetical

Find a Workflow

BaseSpace\_Fetch\_PHB  
V. main  
Source: Dockstore

kSNP4\_PHB  
V. v4.0.0  
Source: Dockstore

SRA\_Fetch\_PHB  
V. v4.0.0  
Source: Dockstore

TheiaProk\_Illumina\_PE\_PHB  
V. main  
Source: Dockstore

TheiaProk\_ONT\_PHB  
V. v4.0.0  
Source: Dockstore

Dónde están disponibles los **flujos de trabajo bioinformáticos** para **realizar análisis**

# Instalación de Flujos de trabajo

WORKSPACES

Workspaces > aphl-personal/APHL\_PAN\_ONTRegional\_2025\_Cordero > Workflows

DASHBOARD DATA ANALYSES **WORKFLOWS** SUBMISSION HISTORY SETTINGS

WORKFLOWS

SEARCH WORKFLOWS Sort By: Alphabetical

Find a Workflow

BaseSpace\_Fetch\_PHB

V. main  
Source: Dockstore

kSNP4\_PHB

V. v4.0.0  
Source: Dockstore

SRA\_Fetch\_PHB

V. v4.0.0  
Source: Dockstore

TheiaProk\_Illumina\_PE\_PHB

V. main  
Source: Dockstore

TheiaProk\_ONT\_PHB

V. v4.0.0  
Source: Dockstore

Es necesario instalar flujos de trabajo en  
Terra

Se comienza con pocos flujos de trabajo o  
con ningún flujo de trabajo

Se instalan únicamente la primera vez,  
luego solo se utilizan.

# Descargamos un flujo de trabajo, como descargar una aplicación

The screenshot shows the Terra Workspaces interface. A modal dialog titled "Find a workflow" is open, displaying two main options: "Dockstore.org" and "Terra Workflow Repository". A blue arrow points to "Dockstore.org", which is described as "A community repository of best practice workflows that offers integration with GitHub." The "Terra Workflow Repository" is described as "A repository of WDL workflows that offers private workflows hosted in the platform." Below these, there are "Curated collections from our community:" including "GATK Best Practices", "WDL Analysis Research Pipelines", "Long Read Pipelines", and "Viral Genomics". At the bottom of the modal, there is a link to "Visit our documentation" and a "Cancel" button. The background interface shows a workspace named "aphl-personal/APHL-Paraguay-ONT-Data2024" with a list of workflows, including "Snippy\_Streamline\_FASTA\_PHB" and "TheiaProk\_ONT\_PHB", each with a version number and source (e.g., "V. v2.2.1 Source: Dockstore").

# Busque el flujo de trabajo que desee use el nombre exacto: TheiaProk\_Illumina\_PE\_PHB

Dockstore

Search

Organizations

About

Docs

Forum

Login

Register

Explore Workflows

Workflows

Tools

Notebooks

Expand All

Collapse All

Reset

Search

Enter search term...

TheiaProk\_Illumina\_PE\_PHB

Open Advanced Search

Category

Search for category

↑↓

SingleCellAnalysis

17

COVID-19

15

MicrobialGenomics

9

RNASeq

9

GenomicsToolsets

8

12 more

Language

WDL

4,942

CWL

232

Nextflow

220

Galaxy

174

Snakemake

1

Copy search link

Search: the Language is WDL

Notice: Your search has returned greater than 200 results, however only 200 results are shown. We recommend that you narrow your search to find more relevant results.

A Workflow can use multiple containers and executes multiple actions or steps, outlined by one or more descriptors.

Sort by

Relevance

Popular Keywords +

broadinstitute/warp/mitochondria\_pipeline

Warp Analysis Research Pipelines

n/a

Last updated Mar 19, 2026

DOI 10.5281/zenodo.16944221

621,525 executions

WDL

broadinstitute/warp/ReblockGVCF

Warp Analysis Research Pipelines

n/a

Last updated Mar 19, 2026

DOI 10.5281/zenodo.3957862

864,727 executions

WDL

theiagen/public\_health\_bioinformatics/TheiaCoV\_FASTA\_PHB

Bioinformatics workflows for genomic characterization, submission preparation, and genomic epidemiology of pathogens of public health concern.

24

# Puede reducir aún más los flujos de trabajo por organización

By using

Search for category

- ☐ COVID-19 10
- ☐ ViralGenomics 3
- ☐ FileConversion 2
- ☐ MicrobialGenomics 1

Language ^

- ☒ WDL 129
- ☐ Nextflow 1

Language Versions ? v

Author ^

Search for author

- ☐ n/a 129

Source Control ^

- ☐ GitHub 129

Organization ^

Search for organization

⬆ ⬇ ⬇ ⬆

- ☒ theiagen 129
- ☐ broadinstitute 887
- ☐ talkowski-lab 178
- ☐ shengqh 56
- ☐ human-pangenomics 55
- ☐ UW-GAC 44

220 more



theiagen

# Encuentre el flujo de trabajo exacto

By using our site, you acknowledge that you have read and understand our [Terms of Service](#) and [Privacy Policy](#). ✕

 [theiagen/public\\_health\\_bioinformatics/TheiaProk\\_Illumina\\_PE\\_PHB](#)

Bioinformatics workflows for genomic characterization, submission preparation, and genomic epidemiology of pathogens of public health concern.

**Path:** `github.com/theiagen/public_health_bioinformatics/TheiaProk_Illumina_PE_PHB`

**Source Files:** `/utilities/wf_read_QC_trim_pe.wdl` as read\_qc workflow `theiaprok_illumina_pe` { meta { description: "De-novo...tbprofiler\_sub\_lineage": merlin\_magic.tbprofiler\_sub\_lineage, "tbprofiler\_version": merlin\_magic.tbprofiler\_version, "theiaprok\_illumina\_pe\_analysis\_date...": version\_capture.date, "theiaprok\_illumina\_pe\_version": version\_capture.phb\_version, "trimmomatic\_docker...read\_QC\_trim.read1\_clean, read2\_clean = read\_QC\_trim.read2\_clean, } } } } output { # Version Captures String theiaprok\_illumina\_pe\_version...= version\_capture.phb\_version String theiaprok\_illumina\_pe\_analysis\_date = version\_capture.date # Read

 n/a  Last updated Mar 18, 2026  DOI [10.5281/zenodo.15587507](#)  314,971 executions

WDL



 [theiagen/public\\_health\\_bioinformatics/TheiaEuk\\_PE](#)

Performs de-novo genome assembly, taxonomic identification, and quality control of paired-end eukaryotic NGS data.  AI

**Description:** # Public Health Bioinformatics (PHB)

**Source Files:** `read2 File midas_db = "gs://theiagen-public-files-rp/terra/theiaprok-files/midas/midas_db_v1.2.tar.gz" { description: "Runs basic QC (fastq_scan), trimming (Trimmomatic), and adapter removal (bbduk) on illumina.../tasks/task_versioning.wdl" as versioning workflow theiaek_illumina_pe { meta { description: "De-novo...read_QC_trim.read1_clean, read2 = read_QC_trim.read2_clean } } } output { # Version Captures String theiaek_illumina_pe_version...= version_capture.phbg_version String theiaek_illumina_pe_analysis_date = version_capture.date # Read`

 n/a  Last updated Mar 21, 2023  718 executions

WDL



 [theiagen/public\\_health\\_bioinformatics/Metabuli\\_PHB](#)

Bioinformatics workflows for genomic characterization, submission preparation, and genomic epidemiology of pathogens of public health concern.

**Description:** Classify ONT/Illumina paired-end reads using Metabuli

**Source Files:** `= "PHB v4.1.0" ~ { default = "export TZ=" + timezone } date +%Y-%m-%d" > TODAY echo "$PHB_Version" &...gt; PHB_VERSION } output { String date = read_string("TODAY") String phb_version = read_string("PHB_VERSION") Int pe_mode = 2 Boolean implicit_illumina = true } if (!...; (select_first([illumina, false]) || defined(implicit_illumina))) { # Trim illumina call fastp_task.fastp... (select_first([illumina, false]) || defined(implicit_illumina)) } call fastplong_task.fastplong { input`

 n/a  Last updated Mar 12, 2026  667 executions

WDL



# Carga con Terra

By using our site, you acknowledge that you have read and understand our [Terms of Service](#) and [Privacy Policy](#). X

 **Dockstore**  Search  Organizations  About  Docs  Forum Login Register

 [Explore Workflows](#) / [github.com/theiagen/public\\_health\\_bioinformatics/TheiaProk\\_Illumina\\_PE\\_PHB](#)

 [github.com/theiagen/public\\_health\\_bioinformatics/TheiaProk\\_Illumina\\_PE\\_PHB:main](#) ☆ 0

Last update to this workflow version: 10 days ago

Last update to source repository: 1 hour ago

Labels: theiagen-phb

Info

Launch

Versions

Files

Tools

DAG

Metrics

### Workflow Information

**Source Code:** [https://github.com/theiagen/public\\_health\\_bioinformatics/tree/main/workflows/theiaprok/wf\\_theiaprok\\_illumina\\_pe.wdl](https://github.com/theiagen/public_health_bioinformatics/tree/main/workflows/theiaprok/wf_theiaprok_illumina_pe.wdl)

**TRS:** [#workflow/github.com/theiagen/public\\_health\\_bioinformatics/TheiaProk\\_Illumina\\_PE\\_PHB](#) 

**Topic:** Bioinformatics workflows for genomic characterization, submission preparation, and genomic epidemiology of pathogens of public health concern.

**Checker Workflow:** n/a

**Descriptor Type:** WDL

### Workflow Version Information

main Export as ZIP

| Author        | Role | Affiliation | Email | ORCID iD |
|---------------|------|-------------|-------|----------|
| Not Available |      |             |       |          |

Export this workflow version to Terra.

Launch with

 DNAnexus

 Terra

 eLwazi

 AnVIL

 NHLBI BioData Catalyst®

Cite this workflow

Version **main** has no DOI.

Cite all versions using the DOI

**DOI** [10.5281/zenodo.15587507](#) This DOI represents all versions, and will always resolve to the latest one.



# Seleccione el destino correcto e importe

 **IMPORT WORKFLOW** 

### Importing from Dockstore

github.com/theiagen/public\_health\_bioinformatics/TheiaProk\_Illumina\_PE\_PHB  
V. main

 Please note: Dockstore cannot guarantee that the WDL and Docker image referenced by this Workflow will not change. We advise you to review the WDL before future runs.

```
1 version 1.0
2
3 import "../../../workflows/utilities/wf_digger_denovo.wdl" as digger_denovo
4 import "../../../tasks/gene_typing/annotation/task_bakta.wdl" as bakta_task
5 import "../../../tasks/gene_typing/annotation/task_prokka.wdl" as prokka_task
6 import "../../../tasks/gene_typing/drug_resistance/task_amrfinderplus.wdl" as amrf
7 import "../../../tasks/gene_typing/drug_resistance/task_resfinder.wdl" as resfinde
8 import "../../../tasks/gene_typing/plasmid_detection/task_plasmidfinder.wdl" as pl
9 import "../../../tasks/gene_typing/drug_resistance/task_abricate.wdl" as abricate_
10 import "../../../tasks/quality_control/advanced_metrics/task_busco.wdl" as busco_t
11 import "../../../tasks/quality_control/advanced_metrics/task_mummer_ani.wdl" as ar
12 import "../../../tasks/quality_control/basic_statistics/task_cg_pipeline.wdl" as c
13 import "../../../tasks/quality_control/basic_statistics/task_quast.wdl" as quast_t
14 import "../../../tasks/quality_control/comparisons/task_qc_check_phb.wdl" as qc_ch
15 import "../../../tasks/quality_control/comparisons/task_screen.wdl" as screen
16 import "../../../tasks/species_typing/multi/task_ts_mlst.wdl" as ts_mlst_task
17 import "../../../tasks/task_versioning.wdl" as versioning
18 import "../../../tasks/taxon_id/contamination/task_kmerfinder.wdl" as kmerfinder_t
19 import "../../../tasks/taxon_id/task_gambit.wdl" as gambit_task
20 import "../../../tasks/gene_typing/drug_resistance/task_gamma.wdl" as gamma_task
21 import "../../../tasks/utilities/data_export/task_export_taxon_table.wdl" as expor
22 import "../../../tasks/utilities/data_handling/task_arln_stats.wdl" as arln_stats
```

### Workflow Name

### Destination Workspace

 aphi-personal / APHL\_PAN\_ONTRegio... 





Or create a new workspace

# Una vez importado, se le dirige al flujo de trabajo

The screenshot displays the Terra Workspaces interface for a workflow named 'TheiaProk\_Illumina\_PE\_PHB'. The top navigation bar includes 'DASHBOARD', 'DATA', 'ANALYSES', 'WORKFLOWS' (selected), and 'SUBMISSION HISTORY'. The workflow details show a version of 'main' sourced from 'github.com/theiagen/public\_health\_bioinformatics/TheiaProk\_Illumina\_PE\_PHB:main'. The synopsis indicates 'No documentation provided'. Two execution options are available: 'Run workflow with inputs defined by file paths' (unselected) and 'Run workflow(s) with inputs defined by data table' (selected). Step 1 shows a data table selection of '2020\_Enterococcus'. Step 2 has a 'Select Data' button and 'No data selected'. Runtime options include a cost threshold set to '\$ Example: 1.00'. Checkboxes for 'Use call caching' (checked), 'Use reference disks', 'Ignore empty outputs', 'Delete intermediate outputs', and 'Resource monitoring' are visible. At the bottom, tabs for 'SCRIPT', 'INPUTS' (selected), and 'OUTPUTS' are shown, along with a 'Launch' button. The 'INPUTS' tab contains a table with two input variables for the 'create\_terra\_table' task.

| Task name ↓        | Variable           | Type    | Input value |
|--------------------|--------------------|---------|-------------|
| create_terra_table | assembly_data      | Boolean | Required    |
| create_terra_table | data_location_path | String  | Required    |

# Pestaña Flujos de trabajo

WORKSPACES

Workspaces > theiagen-demos/TheiaCoV\_Training\_Demos > Workflows

DASHBOARD DATA ANALYSES **FLUJOS DE TRABAJO**

WORKFLOWS

SEARCH WORKFLOWS Sort By: Alphabetical

ENCONTRAR UN FLUJO DE TRABAJO

Concatenate\_Column\_Content  
V. v1.3.4  
Source: Dockstore

Mercury\_Batch  
V. v2.1.0  
Source: Dockstore

Mercury\_PE\_Pre  
V. v2.1.0  
FUENTE: Dockstore

Mercury\_SE\_Pre  
V. v2.1.0  
Source: Dockstore

TheiaCoV\_Augur\_Pre  
V. v2.1.0  
Source: Dockstore

TheiaCoV\_Augur\_Run  
V. v2.1.0  
Source: Dockstore

TheiaCoV\_Illumina\_PE  
V. v2.1.0  
Source: Dockstore

TheiaCoV\_ONT  
V. v2.1.0  
Source: Dockstore

Zip\_Column\_Content  
V. v1.3.4  
Source: Dockstore

Rate: \$0.00 per hour

Donde están disponibles los **flujos de trabajo bioinformáticos** para **realizar análisis**

# Interfaz de flujo de trabajo

The screenshot displays the Terra Workspaces interface for a workflow named 'TheiaProk\_Illumina\_PE'. The interface includes a top navigation bar with 'WORKSPACES' and a breadcrumb trail: 'Workspaces > theiagen\_pnl/TheiaProk\_PNI\_Training\_DEMO > workflows > TheiaProk\_Illumina\_PE'. A secondary navigation bar contains tabs for 'DASHBOARD', 'DATA', 'ANALYSES', 'FLUJOS DE TRABAJO' (selected), and 'JOB HISTORY'. The main content area shows the workflow details, including its version (v1.0.0), source (github.com/theiagen/public\_health\_bacterial\_genomics/TheiaProk\_Illumina\_PE:v1.0.0), and a synopsis. Below this, there are two steps for configuring the workflow: 'Step 1' for selecting the root entity type and 'Step 2' for selecting data. A 'SELECT DATA' button is present, and a message indicates 'No data selected'. At the bottom, there are checkboxes for 'Use call caching', 'Delete intermediate outputs', 'Use reference disks', and 'Retry with more memory'. A 'RUN ANALYSIS' button is also visible. The bottom section of the interface shows a table of inputs with columns for 'Task name', 'Variable', 'Type', and 'Attribute'.

Version: v1.0.0

Source: github.com/theiagen/public\_health\_bacterial\_genomics/TheiaProk\_Illumina\_PE:v1.0.0

Synopsis: No documentation provided

Run workflow with inputs defined by file paths

EJECUTAR FLUJOS DE TRABAJO CON ENTRADAS DEFINIDAS POR TABLA DE DATOS

Step 1

Select root entity type: Select data type...

Step 2

SELECT DATA No data selected

Use call caching Delete intermediate outputs Use reference disks Retry with more memory

SCRIPT \*\* ENTRADAS \*\* OUTPUTS \*\* RUN ANALYSIS

| Task name ↓           | Variable   | Type   | Attribute |
|-----------------------|------------|--------|-----------|
| theiaprok_illumina_pe | read1_raw  | File   | Required  |
| theiaprok_illumina_pe | read2_raw  | File   | Required  |
| theiaprok_illumina_pe | samplename | String | Required  |

Permite a los usuarios **iniciar flujos de trabajo bioinformáticos** para **realizar análisis**

**Ejecutar un flujo de  
trabajo en Terra**

# Flujos de trabajo de Terra

- Una vez cargados los datos en Terra y organizados en una tabla de datos, podemos analizarlos con un flujo de trabajo
- Flujos de trabajo
  - Se pueden tomar entradas de una tabla de datos de Terra
  - Rellenar salidas en una tabla de datos de Terra

# Configuración del flujo de trabajo (workflow)

The screenshot displays the Terra Workspaces interface. At the top, the breadcrumb path is "Workspaces > theiagen-training-workspaces/HSDH\_Training\_TEMPLATE > Workflows". The navigation bar includes "DASHBOARD", "DATA", "ANALYSES", and "FLUJOS DE TRABAJO", with the latter being the active tab. A blue arrow points to this tab. Below the navigation bar, the "WORKFLOWS" section is visible. It includes a "SEARCH WORKFLOWS" input field, a "Sort By: Alphabetical" dropdown, and view toggle buttons (grid and list). A list of workflow cards is shown, each with a title, version (V. v1.3.0), and source (Source: Dockstore). A blue arrow points to the "TheiaProk\_Illumina\_PE\_PHB" workflow card. The right sidebar shows a "Rate: \$0.00 per hour" and a cloud icon.

WORKSPACES Workspaces > theiagen-training-workspaces/HSDH\_Training\_TEMPLATE > Workflows

DASHBOARD DATA ANALYSES **FLUJOS DE TRABAJO**

WORKFLOWS

SEARCH WORKFLOWS Sort By: Alphabetical

Find a Workflow

Kraken2\_PE\_PHB  
V. v1.3.0  
Source: Dockstore

kSNP3\_PHB  
V. v1.3.0  
Source: Dockstore

Snippy\_Streamline\_PHB  
V. v1.3.0  
Source: Dockstore

SRA\_Fetch\_PHB  
V. v1.3.0  
Source: Dockstore

Terra\_2\_NCBI\_PHB  
V. v1.3.0  
Source: Dockstore

TheiaProk\_Illumina\_PE\_PHB  
V. v1.3.0  
FUENTE: Dockstore

Rate: \$0.00 per hour

# Configuración del flujo de trabajo

WORKSPACES Workspaces > theiagen-training-workspaces/HSDH\_Training\_TEMPLATE > workflows > TheiaProk\_Illumina\_PE\_PHB

DASHBOARD DATA ANALYSES **FLUJOS DE TRABAJO** JOB HISTORY

← Back to list

ⓘ TheiaProk\_Illumina\_PE\_PHB

Version **v4.1.0** ▾

Source: [github.com/theiagen/public\\_health\\_bioinformatics/TheiaProk\\_Illumina\\_PE\\_PHB:v1.3.0](https://github.com/theiagen/public_health_bioinformatics/TheiaProk_Illumina_PE_PHB:v1.3.0)

Synopsis:

No documentation provided

☐ Run workflow with inputs defined by file paths

☒ EJECUTAR FLUJOS DE TRABAJO CON ENTRADAS DEFINIDAS POR TABLA DE DATOS

**Step 1**

SELECCIONAR TABLA DE DATOS SELECCIONAR TIPO DE DATOS ▾

**Step 2**

SELECCIONAR DATOS SIN DATOS SELECCIONADOS

☒ Use call caching ⓘ ☐ Delete intermediate outputs ⓘ ☐ Use reference disks ⓘ ☐ Retry with more memory ⓘ ☐ Ignore empty outputs ⓘ

SCRIPT •• **ENTRADAS** ⓘ •• OUTPUTS •• RUN ANALYSIS

Hide optional inputs

| Task name ↓           | Variable  | Type | Input value |
|-----------------------|-----------|------|-------------|
| theiaprok_illumina_pe | read1_raw | File | Required    |



# Configuración del flujo de trabajo

DASHBOARD

DATA

ANALYSES

WORKFLOWS

SUBMISSION HISTORY

SETTINGS

← Back to list

ⓘ

TheiaProk\_Illumina\_PE\_PHB

Version:

v4.1.0

▼

Source: [github.com/theiagen/public\\_health\\_bioinformatics/TheiaProk\\_Illumina\\_PE\\_PHB:v4.1.0](https://github.com/theiagen/public_health_bioinformatics/TheiaProk_Illumina_PE_PHB:v4.1.0)

Synopsis:

No documentation provided

☐ Run workflow with inputs defined by file paths

☒ Run workflow(s) with inputs defined by data table

Step 1

Select data table: 2020\_Enterococcus ▼

Runtime options: ⓘ

Set cost threshold per workflow: \$ Example: 1.00

[Learn more about how Ter](#)

☒ Use call caching ⓘ

☐ Delete intermediate outputs

SCRIPT

Step 2

Select Data No data selected

ⓘ

Ignore empty outputs ⓘ

☐ Resource monitoring ⓘ

OUTPUTS

Launch

Cancel

Save


Seleccionar la más reciente

Seleccionar la tabla de datos que se quiere trabajar (Usar la que no dice \_set)

Hide optional inputs

[Download json](#) | [Drag or click to upload json](#) | [Clear inputs](#)

# Configuración del flujo de trabajo



← Back to list

## TheiaProk\_Illumina\_PE\_PHB

Version: v4.1.0

Source: [github.com/theiagen/public\\_health\\_bioinformatics/TheiaProk\\_Illumina\\_PE\\_PHB:v4.1.0](https://github.com/theiagen/public_health_bioinformatics/TheiaProk_Illumina_PE_PHB:v4.1.0)

Synopsis:

No documentation provided

- ☐ Run workflow with inputs defined by file paths
- ☒ Run workflow(s) with inputs defined by data table

### Step 1

Input: 2020\_Enterococcus

Runtime options:

Set cost threshold per workflow

\$ Example: 1.00

[Learn more about how Terra implements cost thresholds](#)

- ☒ Use call caching
- ☐ Use reference disks
- ☐ Ignore empty outputs
- ☐ Delete intermediate outputs
- ☐ Resource monitoring

### Step 2

Select Data

No data selected

## Select Data

- ☒ Choose specific 2020\_Enterococcus to process
- ☐ Choose existing sets of 2020\_Enterococcus

Select 2020\_Enterococcus to process

[Settings](#)

0 rows selected

| <input type="checkbox"/> | 2020_E...      | abricate_abaum_database | abricate_abaum_docker | abricate_abaum_plasmid |
|--------------------------|----------------|-------------------------|-----------------------|------------------------|
| <input type="checkbox"/> | 8401_S2_L...   |                         |                       |                        |
| <input type="checkbox"/> | 9455_S3_L...   |                         |                       |                        |
| <input type="checkbox"/> | 553768_S5_L... |                         |                       |                        |

No marcar esta opción

SCRIPT INPUTS OUTPUTS Launch

# Configuración del flujo de trabajo

Step 1

Select data table: training\_data\_bact... ▾

Step 2

SELECCIONAR DATOS

30 selected training\_data\_bacterials (will create a new training\_data\_bacterial\_set named "TheiaProk\_Illumina\_PE\_PHB\_2024-02-15T16-11-23")

☒ Use call caching ⓘ

☐ Delete intermediate outputs ⓘ

☐ Use reference disks ⓘ

☐ Retry with more memory ⓘ

☒ Ignore empty outputs ⓘ

SCRIPT

••

INPUTS

••

OUTPUTS

••

Launch

CANCEL

GUARDAR

Hide optional inputs

Download json | Drag or click to upload json | Clear inputs

SEARCH INPUTS

Configuración del flujo de trabajo

Hide optional inputs

Download json | Drag or click to upload json | Clear inputs

SEARCH INPUTS

| Task name ↓           | Variable ↓                | Type    | Input value                             |
|-----------------------|---------------------------|---------|-----------------------------------------|
| amrfinderplus_task    | detailed_drug_class       | Boolean | <input type="text" value="true"/> {...} |
| amrfinderplus_task    | separate_betalactam_genes | Boolean | <input type="text" value="true"/> {...} |
| merlin_magic          | call_stxtyper             | Boolean | <input type="text" value="true"/> {...} |
| merlin_magic          | ectyper_print_alleles     | Boolean | <input type="text" value="true"/> {...} |
| merlin_magic          | paired_end                | Boolean | <input type="text" value="true"/> {...} |
| merlin_magic          | run_amr_search            | Boolean | <input type="text" value="true"/> {...} |
| merlin_magic          | sistr_use_full_cgmlst_db  | Boolean | <input type="text" value="true"/> {...} |
| read_QC_trim          | call_kraken               | Boolean | <input type="text" value="true"/> {...} |
| read_QC_trim          | call_midas                | Boolean | <input type="text" value="true"/> {...} |
| resfinder_task        | call_pointfinder          | Boolean | <input type="text" value="true"/> {...} |
| theiaprok_illumina_pe | call_abricate             | Boolean | <input type="text" value="true"/> {...} |
| theiaprok_illumina_pe | call_anii                 | Boolean | <input type="text" value="true"/> {...} |
| theiaprok_illumina_pe | call_kmerfinder           | Boolean | <input type="text" value="true"/> {...} |
| theiaprok_illumina_pe | call_plasmidfinder        | Boolean | <input type="text" value="true"/> {...} |
| theiaprok_illumina_pe | call_resfinder            | Boolean | <input type="text" value="true"/> {...} |

# Configuración del flujo de trabajo

Step 1

Select data table: training\_data\_bact... ▼

Step 2

SELECCIONAR DATOS

30 selected training\_data\_bacterials (will create a new training\_data\_bacterial\_set named "TheiaProk\_Illumina\_PE\_PHB\_2024-02-15T16-11-23")

☒ Use call caching ⓘ

☐ Delete intermediate outputs ⓘ

☐ Use reference disks ⓘ

☐ Retry with more memory ⓘ

☒ Ignore empty outputs ⓘ

SCRIPT

\*\*

INPUTS ⓘ

\*\*

**SALIDAS** 

ANALYSIS

Output files will be saved to

Files / submission unique ID / theiaprok\_illumina\_pe / workflow unique ID

References to outputs will be written to

Tables / training\_data\_bacterial

Fill in the attributes below to add or update columns in your data table

CANCEL

**GUARDAR** 

Download json | Drag or click to upload json | Clear outputs

SEARCH OUTPUTS

| Task name ↓           | Variable                          | Type   | Input value   UTILIZAR VALORES POR DEFECTO  |
|-----------------------|-----------------------------------|--------|--------------------------------------------------------------------------------------------------------------------------------|
| theiaprok_illumina_pe | abricate_abaum_plasmid_tsv        | File   | <input type="text" value="this.abricate_abaum_plasmid_tsv"/> <span>[...]</span>                                                |
| theiaprok_illumina_pe | abricate_abaum_plasmid_type_genes | String | <input type="text" value="this.abricate_abaum_plasmid_type_genes"/> <span>[...]</span>                                         |
| theiaprok_illumina_pe | abricate_database                 | String | <input type="text" value="this.abricate_database"/> <span>[...]</span>                                                         |
| theiaprok_illumina_pe | abricate_docker                   | String | <input type="text" value="this.abricate_docker"/> <span>[...]</span>                                                           |
| theiaprok_illumina_pe | abricate_version                  | String | <input type="text" value="this.abricate_version"/> <span>[...]</span>                                                          |

# Configuración del flujo de trabajo

The screenshot displays the Terra Workspaces interface for configuring a workflow. The top navigation bar includes the Terra logo, 'WORKSPACES', and a breadcrumb trail: 'Workspaces > theiagen-training-workspaces/HSDH\_Training\_TEMPLATE > workflows > TheiaProk\_Illumina\_PE\_PHB'. Below this, a secondary navigation bar contains 'DASHBOARD', 'DATA', 'ANALYSES', 'FLUJOS DE TRABAJO' (highlighted), and 'JOB HISTORY'.

The main content area shows the workflow 'TheiaProk\_Illumina\_PE\_PHB' with a version dropdown set to 'v1.3.0'. The source is 'github.com/theiagen/public\_health\_bioinformatics/TheiaProk\_Illumina\_PE\_PHB:v1.3.0'. The synopsis states 'No documentation provided'. Two execution options are available: 'Run workflow with inputs defined by file paths' (unselected) and 'Run workflow(s) with inputs defined by data table' (selected).

The configuration is divided into two steps. Step 1, 'Select data table:', has a dropdown menu showing 'training\_data\_bact...'. Step 2, 'SELECCIONAR DATOS', shows '30 selected training\_data\_bacterials (will create a new training\_data\_bacterial\_set named "TheiaProk\_Illumina\_PE\_PHB\_2024-02-15T16-11-23")'. Below the steps, there are checkboxes for 'Use call caching' (checked), 'Delete intermediate outputs' (unchecked), 'Use reference disks' (unchecked), 'Retry with more memory' (unchecked), and 'Ignore empty outputs' (checked).

At the bottom, there are tabs for 'SCRIPT', 'ENTRADAS' (highlighted), and 'OUTPUTS'. A blue button labeled 'INICIAR ANÁLISIS' is positioned to the right of the 'ENTRADAS' tab, with a large blue arrow pointing to it. Below the tabs, there is a section for 'Hide optional inputs' with links for 'Download json', 'Drag or click to upload json', and 'Clear inputs', along with a 'SEARCH INPUTS' search bar.

| Task name ↓           | Variable  | Type | Input value |
|-----------------------|-----------|------|-------------|
| theiaprok_illumina_pe | read1_raw | File | this.read1  |

# Pestaña de historial

WORKSPACES BETA

Workspaces > theiagen-validations/Theiagen\_Doughty\_Sandbox > Job History

COVID-19 Data & Tools

DASHBOARD DATA ANALYSES WORKFLOWS **HISTORIAL**

Search

Rate: \$0.00 per hour

| Submission (click for details)                                                     | Data entity                | No. of Workflows | Status | Submitted            | Submission ID                                     | Comment                   | Actions |
|------------------------------------------------------------------------------------|----------------------------|------------------|--------|----------------------|---------------------------------------------------|---------------------------|---------|
| <b>Snippy_Streamline_PHB</b><br>Submitted by emma.doughty@theiagen.com             | Snippy_Streamline_PHB_...  | 1                | ✓ Done | May 19, 2023 5:53 PM | 070dc07e-298a-4500-8fa7-3833c516b36d              | Core_genome and use_gu... | ⓘ       |
| <b>Snippy_Streamline_PHB_FJQXGBenZY8</b><br>Submitted by emma.doughty@theiagen.com | Core_genome_no_model (...) | 1                | ✓ Done |                      |                                                   |                           |         |
| <b>Snippy_Streamline_PHB_eXv253XmVJk</b><br>Submitted by emma.doughty@theiagen.com | core_genome_not_specifi... | 1                | ✓ Done |                      |                                                   |                           |         |
| <b>Snippy_Streamline_PHB_uS7CqKdwTLs</b><br>Submitted by emma.doughty@theiagen.com | Core_genome_no_model (...) | 1                | ✓ Done |                      |                                                   |                           |         |
| <b>kSNP3_PHB</b><br>Submitted by emma.doughty@theiagen.com                         | kSNP3_2023-05-17T15-...    | 1                | ✓ Done |                      |                                                   |                           |         |
| <b>kSNP3_PHB_p6KVTH0yNpE</b><br>Submitted by emma.doughty@theiagen.com             | kSNP3_2023-05-17T15-...    | 1                | ⚠ Done | May 17, 2023 5:15 PM | fd3a2038-4607-4254-9540-                          |                           | ⓘ       |
| <b>kSNP3</b><br>Submitted by emma.doughty@theiagen.com                             | kSNP3_2023-05-17T15-...    | 1                | ⚠ Don  |                      |                                                   |                           |         |
| <b>kSNP3_7kiEzqom2aw</b><br>Submitted by emma.doughty@theiagen.com                 | kSNP3_2023-05-17T15-...    | 5                | ⚠ Don  |                      |                                                   |                           |         |
| <b>kSNP3_tOnibN-HuJM</b><br>Submitted by emma.doughty@theiagen.com                 | kSNP3_2023-05-17T12-...    | 1                | ⚠ Don  |                      |                                                   |                           |         |
| <b>kSNP3_i_0oxOJRalk</b><br>Submitted by emma.doughty@theiagen.com                 | kSNP3_2023-05-17T12-...    | 1                | ⚠ Done | May 17, 2023 2:09 PM | 81a1fa1d0084-824519c4-026f-4627-be78-fc12aa484d61 |                           | ⓘ       |

Registro de todos los **flujos de trabajo bioinformáticos** iniciados para su **análisis en el espacio de trabajo**

Útil para **solucionar fallos en el trabajo**

# La interfaz que ves...


The screenshot displays the Terra WORKSPACES interface. The top navigation bar includes the Terra logo, a 'BETA' label, and the text 'WORKSPACES'. Below this, a breadcrumb trail shows 'Workspaces > theiagen-demos/TheiaCoV\_Training\_Demos > Data'. On the right, there's a 'COVID-19 Data & Tools' button and a notification bell with a '1' indicator.

The main interface is divided into several sections:

- Navigation Tabs:** DASHBOARD, DATOS (active), ANALYSES, WORKFLOWS, and JOB HISTORY.
- Table Actions:** A row of buttons for 'IMPORT DATA', 'EDIT', 'OPEN WITH...', 'EXPORT', and 'SETTINGS'. It also shows '0 rows selected' and an 'ADVANCED SEARCH' button.
- Table Structure:** The table has columns for file types: 'Illumina...', 'aligned\_bai', 'aligned\_bam', 'assembly\_fasta', and 'assembly\_length\_unambig'. Each row represents a specific dataset, such as 'hCoV-19\_USA\_CA-QDX-2781\_2...'.
- Left Sidebar:** Contains a 'TABLES' section with a search bar and a list of tables, including 'Illumina\_PE\_v2-1-2 (25)'. Below this is a 'REFERENCE DATA' section with a message 'No references have been added. Add reference data'. At the bottom is an 'OTHER DATA' section with links to 'Workspace Data' and 'Files'.
- Right Sidebar:** Displays a 'Rate: \$0.00 per hour' and a lightning bolt icon.
- Footer:** Shows pagination information: '1 - 25 of 25' and 'Items per page: 100'.



# Flujos de trabajo de TheiaProk (v2.0.1)




Cribado=screening


QC= control de calidad

## Lo que sucede detrás...

Terra es una **aplicación web** que conecta a los usuarios con **flujos de trabajo bioinformáticos** y **recursos dinámicos de computación en nube** a través de una **interfaz gráfica de usuario (GUI)**



# Flujos de trabajo de TheiaProk (v2.0.1)




# Fases del análisis bioinformático

## Análisis bioinformático (Illumina)

- **Pre procesamiento de datos:** Eliminación de lecturas de baja calidad, adaptadores y secuencias de recorte (limpieza de lecturas)
- **Ensamblaje de novo** (si procede): Ensamblaje de secuencias en contigs más largos sin genoma de referencia
- **Identificación taxonómica:** Identificación del género y la especie a la que pertenece la muestra
- **Anotación:** Anotación de variantes genéticas y predicción de su impacto funcional
- **Caracterización genómica:** Identificación de las características genómicas que confieren cualidades fenotípicas como la resistencia a los antibióticos




# Flujos de trabajo de TheiaProk (v2.0.1)




## Tamizaje de lectura (screening)

- Evalúa la **cantidad de datos** para detener el procesamiento de muestras con datos insuficientes y evitar el desperdicio de recursos informáticos
- Se realiza como primer paso del flujo de trabajo
- Se repite tras la limpieza de lecturas



## El tamizaje o screening de lectura verifica...

1. Número total de lecturas
2. Proporción de pares de bases de lecturas en los archivos de lectura directa e inversa
3. Número de pares de bases
4. Tamaño estimado del genoma
5. Cobertura estimada del genoma



# Salidas (outputs) de Tamizaje de lecturas

- **Raw\_read\_screen:** Aprobado o No Aprobado
- **Clean\_read\_screen:** Aprobado o No Aprobado

Si una muestra no supera el tamizaje o screening, TheiaProk se detiene, conservando los recursos




The “raw\_read\_screen” column under “QC\_metrics” will give details if the sample fails the read pre-screen:


The screenshot shows the Terra.BIO WORKSPACES interface. The top navigation bar includes 'DASHBOARD', 'DATA', 'ANALYSES', 'WORKFLOWS', and 'JOB HISTORY'. The 'DATA' tab is active, displaying a table of sequencing data. The table has columns for 'analysis\_pt\_24\_id', 'n50\_value', 'number\_contigs', 'raw\_read\_screen', and 'seqero2\_predicted\_contamina...'. The 'raw\_read\_screen' column is circled in red, indicating a 'FAIL' status for the sample '2013L-5615TK\_NextSeq\_400MB'. The failure message is: 'FAIL; the estimated coverage is less than the minimum of 10x'.

| analysis_pt_24_id            | n50_value | number_contigs | raw_read_screen                                              | seqero2_predicted_contamina... |
|------------------------------|-----------|----------------|--------------------------------------------------------------|--------------------------------|
| 2011V-1043_FLEX_300_Vibrio   | 124949    | 77             | PASS                                                         |                                |
| 2012V-1116_FLEX_300_Vibrio   | 458045    | 39             | PASS                                                         |                                |
| 2013L-5361_FLEX_300_LM       | 526928    | 12             | PASS                                                         |                                |
| 2013L-5410_FLEX_300_LM       | 528025    | 15             | PASS                                                         |                                |
| 2013L-5547_FLEX_300_LM       | 435363    | 20             | PASS                                                         |                                |
| 2013L-5615TK_NextSeq_400MB   |           |                | FAIL; the estimated coverage is less than the minimum of 10x |                                |
| 2015AM-1304                  | 443204    | 15             | PASS                                                         | yes                            |
| 2015AM-1305                  | 728098    | 16             | PASS                                                         | no                             |
| 2015C-3794_FLEX_300_Shigella | 25104     | 361            | PASS                                                         |                                |
| 2015C-5131_FLEX_300_Ecoli    | 87650     | 705            | PASS                                                         |                                |

# Flujos de trabajo de TheiaProk (v2.0.1)




## Recorte de lectura: Trimmomatic y BBDuk





# En detalle: Recorte de ventana deslizable





# Recorte de lectura y retirada del adaptador

## Salidas


- **Lecturas limpias** (lecturas de alta calidad, sin secuencias adaptadoras)
  - Utilizarlas para cualquier proceso posterior basado en lecturas, por ejemplo, en el ensamblaje o la caracterización de TheiaProk y en el flujo de trabajo Snippy\_Variants

# Recuerde...

El tamizaje o screening de lecturas se realiza de nuevo después de la limpieza de lecturas para garantizar que hay suficientes lecturas después de la limpieza para proporcionarnos **potencialmente** un buen genoma bacteriano




# Flujos de trabajo de TheiaProk (v2.0.1)



**fastq-scan** cuantifica las lecturas forward y reverse en archivos FASTQ y proporciona el número total de pares de lecturas. Esta tarea se ejecuta una vez con lecturas sin procesar como entrada y otra vez con lecturas limpias como entrada. Si el control de calidad se ha realizado correctamente, debería haber menos lecturas limpias que lecturas sin procesar.

**Cobertura genómica estimada : CG-pipeline**



Genera métricas sobre la calidad de lectura y **estima la cobertura del genoma** tanto para las lecturas crudas como limpias, empleando un tamaño de genoma proporcionado por el usuario o la longitud estimada del genoma generada por QUAST.

# MIDAS (tarea opcional)



Sistema de análisis metagenómico de la diversidad intraespecie

(Metagenomic Intra-species Diversity Analysis System)

Estima la abundancia de especies bacterianas y la variación genómica a nivel de cepa, es decir, la **contaminación con taxones no objetivo**

- Si se identifica un taxón no objetivo >1%, la muestra no pasa el control de calidad y debe investigarse más a fondo

A



# Interpretación de los resultados de la calidad de lectura

Principalmente para identificar errores de secuenciación

**Longitud media de lectura:** Demasiado baja = preparación fragmentada de la biblioteca

**Cobertura estimada del genoma:**

Demasiado baja= demasiada multiplexación, biblioteca de entrada insuficiente

| Key    | Microorganismo             | Genome size | GC_content | assembly_length | combined_mean_q_clean | combined_mean_readlength_clean | est_coverage_clean | midas_primary_genus | midas_secondary_genus                                |
|--------|----------------------------|-------------|------------|-----------------|-----------------------|--------------------------------|--------------------|---------------------|------------------------------------------------------|
| 863563 | Enterococcus faecalis      | 2,9         | 37,5       | 2976000         | 36,42                 | 237,36                         | 84,84              | Enterococcus        | No secondary genus detected (>1% relative abundance) |
| 864548 | Enterococcus faecalis      | 2,9         | 37,5       | 3213656         | 36,75                 | 239,37                         | 59,99              | Enterococcus        | No secondary genus detected (>1% relative abundance) |
| 864690 | Mycobacterium tuberculosis | 4,4         | 65,5       | 4308584         | 35,59                 | 210,87                         | 106,79             | Mycobacterium       | No secondary genus detected (>1% relative abundance) |
| 864691 | Mycobacterium tuberculosis | 4,4         | 65,5       | 4283216         | 35,6                  | 203,67                         | 76,12              | Mycobacterium       | No secondary genus detected (>1% relative abundance) |
| 867508 | Enterococcus faecalis      | 2,9         | 37,5       | 2869306         | 36,5                  | 238,5                          | 30,24              | Enterococcus        | No secondary genus detected (>1% relative abundance) |
| 870312 | Mycobacterium tuberculosis | 4,4         | 65,5       | 4304365         | 35,48                 | 214,48                         | 109,33             | Mycobacterium       | No secondary genus detected (>1% relative abundance) |
| 877774 | Enterococcus durans        | 3           | 38         | 3177186         | 36,72                 | 238,89                         | 52,32              | Enterococcus        | No secondary genus detected (>1% relative abundance) |
| 878099 | Mycobacterium tuberculosis | 4,4         | 65,5       | 4313333         | 35,32                 | 211,72                         | 103,47             | Mycobacterium       | No secondary genus detected (>1% relative abundance) |
| 883080 | Mycobacterium tuberculosis | 4,4         | 65,5       | 4327738         | 35,28                 | 205,63                         | 68,59              | Mycobacterium       | No secondary genus detected (>1% relative abundance) |
| 889411 | Salmonella                 | 5           | 52         | 5052385         | 35,92                 | 228,04                         | 66,35              | Salmonella          | No secondary genus detected (>1% relative abundance) |
| 892310 | Salmonella                 | 5           | 52         | 4724035         | 35,79                 | 227,63                         | 38                 | Salmonella          | No secondary genus detected (>1% relative abundance) |

**Calidad media de las lecturas:** Demasiado baja = error en la preparación de la biblioteca o en la secuenciación; los datos no son exactos

**MIDAS:** Alta abundancia de género secundario = probablemente contaminado

## Appendix PNID01-4a. PulseNet Critical (Pass/Fail) Quality Metrics for Routine Sequence Submissions

| Organism                          | Average denovo coverage <sup>1</sup> | Average quality (Q score) <sup>2</sup> | Assembly length (MB) | Secondary species abundance |
|-----------------------------------|--------------------------------------|----------------------------------------|----------------------|-----------------------------|
| <i>Listeria monocytogenes</i>     | ≥ 20x                                | ≥ 30                                   | 2.8-3.2              | ≤ 0.01                      |
| <i>E. coli</i> (most serotypes)   | ≥ 40x                                | ≥ 30                                   | 4.9-6.0              | ≤ 0.01                      |
| <i>Shigella spp./Rare E. coli</i> | ≥ 40x                                | ≥ 30                                   | 4.2-4.9              | ≤ 0.01                      |
| <i>Salmonella spp.</i>            | ≥ 30x                                | ≥ 30                                   | 4.4-5.7              | ≤ 0.01                      |
| <i>Campylobacter spp.</i>         | ≥ 20x                                | ≥ 30                                   | 1.4-2.2              | ≤ 0.01                      |
| <i>Vibrio cholerae</i>            | ≥ 40x                                | ≥ 30                                   | 3.8-4.3              | ≤ 0.01                      |
| <i>Vibrio parahaemolyticus</i>    | ≥ 40x                                | ≥ 30                                   | 4.9-5.5              | ≤ 0.01                      |
| <i>Vibrio vulnificus</i>          | ≥ 40x                                | ≥ 30                                   | 4.7-5.3              | ≤ 0.01                      |

<sup>1</sup>After quality-based trimming (est\_coverage\_clean)

<sup>2</sup>Before trimming (combined\_mean\_q\_raw)



# Fases del análisis bioinformático


## Análisis bioinformático (Illumina)

- **Pre procesamiento de datos:** Eliminación de lecturas de baja calidad, adaptadores y secuencias de recorte (limpieza de lecturas)
- **Ensamblaje de novo** (si procede): Ensamblaje de secuencias en contigs más largos sin genoma de referencia
- **Identificación taxonómica:** Identificación del género y la especie a la que pertenece la muestra
- **Anotación:** Anotación de variantes genéticas y predicción de su impacto funcional
- **Caracterización genómica:** Identificación de las características genómicas que confieren cualidades fenotípicas como la resistencia a los antibióticos



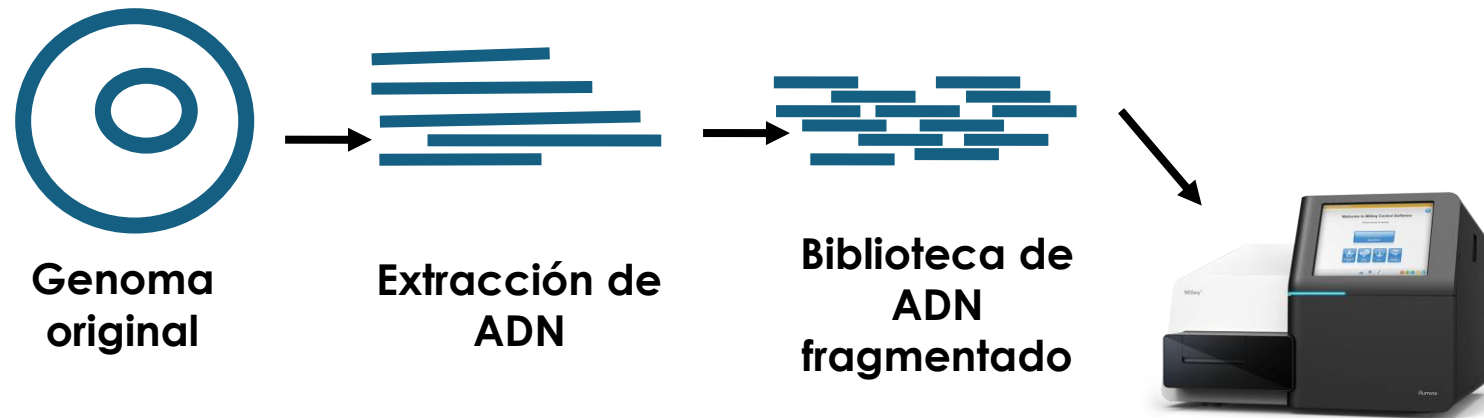


# Flujos de trabajo de TheiaProk (v2.0.1)




# Ensamblaje *De novo*: Illumina

Construye una estimación del genoma original a partir de datos WGS



El ensamblaje *De novo* de lecturas cortas da lugar a muchos contigs



# Ensamblaje *De novo*: Skesa

- Ensamblador *de novo* diseñado específicamente para lecturas cortas de Illumina
- **Prioriza la precisión sobre la contigüidad.**
- Funciona mediante un enfoque de grafo de De Bruijn, utilizando k-meros para construir contigs.
- Elimina errores y burbujas, y es altamente eficiente para genomas bacterianos.

Souvorov et al. *Genome Biology* (2018) 19:153  
<https://doi.org/10.1186/s13059-018-1540-z>

Genome Biology

SOFTWARE

Open Access

## SKESA: strategic k-mer extension for scrupulous assemblies

Alexandre Souvorov<sup>1</sup>, Richa Agarwala<sup>1\*</sup>  and David J. Lipman<sup>1,2</sup>

### Abstract

SKESA is a DeBruijn graph-based de-novo assembler designed for assembling reads of microbial genomes sequenced using Illumina. Comparison with SPAdes and MegaHit shows that SKESA produces assemblies that have high sequence quality and contiguity, handles low-level contamination in reads, is fast, and produces an identical assembly for the same input when assembled multiple times with the same or different compute resources. SKESA has been used for assembling over 272,000 read sets in the Sequence Read Archive at NCBI and for real-time pathogen detection. Source code for SKESA is freely available at <https://github.com/ncbi/SKESA/releases>.

**Keywords:** Illumina reads, De-novo assembly, DeBruijn graphs, Sequence quality, Contamination

Souvorov, A., Agarwala, R. & Lipman, D. SKESA: strategic k-mer extension for scrupulous assemblies. *Genome Biol* 19, 153 (2018). <https://doi.org/10.1186/s13059-018-1540-z>

### 1. Cuenta k-mers confiables

- Solo usa k-mers con buena frecuencia (evita errores de secuenciación)

### 2. Encuentra extensiones seguras

- Empieza con un k-mer y lo extiende **solo si hay UNA opción clara.**
- Ejemplo:
  - ATGCG → puede extender a:
    - ATGCGT (90% de lecturas)
    - ATGCGC (10%, error)
  - SKESA elige ATGCGT

### 3. Evita ambigüedades

- Si encuentra esto:
  - ATGCG → ATGCGT
  - ATGCG → ATGCGC
- Y ambas opciones son posibles:
  - **SKESA se detiene**

# Ensamblaje *De Novo*      Salidas

Ensambladores *De novo* disponibles:


- skesa (por defecto)
- SPAdes
- megahit
- velvet



**Ensamblaje fasta-** archivo que contiene los contigs ensamblados, producido por Shovill

- Se utiliza para la caracterización basada en el ensamblaje

# Flujos de trabajo de TheiaProk (v2.0.1)



# Control de calidad del ensamblaje *De novo*

# Control de calidad del ensamblaje

|    |               |                                                                                     |                                                                |
|----|---------------|-------------------------------------------------------------------------------------|----------------------------------------------------------------|
| 01 | Compleitud    | ¿Está representado todo el genoma en los datos de la secuencia y el ensamblaje?     | Longitud del genoma<br>Cobertura estimada<br>BUSCO             |
| 02 | Contigüidad   | ¿Hasta qué punto está fragmentado el ensamblaje?                                    | # Contigs                                                      |
| 03 | Correctitud   | ¿Es correcto el ensamblaje por base y están correctamente ensambladas las lecturas? | Calidad media de lectura<br>Identificación taxonómica<br>BUSCO |
| 04 | Contaminación | ¿Son (suficientes) las lecturas del organismo objetivo?                             | Longitud de ensamblaje<br>Identificación taxonómica<br>BUSCO   |

# Herramienta de control de calidad del ensamblaje: QUAST

Número de contigs



5.4 Quality control threshold guidelines for the GenomeTrakr surveillance network. These are also relevant for NARMS and VetLIRN contributors.

\*MicroRunQC users should follow threshold guidelines established by their respective surveillance coordinating body(s).


Menos es mejor

| A                                          | B          | C        | D        | E        | F             | G            | H           |
|--------------------------------------------|------------|----------|----------|----------|---------------|--------------|-------------|
| Quality metric                             | Salmonella | Listeria | E. coli  | Shigella | Campylobacter | Vibrio para. | Cronobacter |
| Average read quality Q score for R1 and R2 | >=30       | >=30     | >=30     | >=30     | >=30          | >=30         | >=30        |
| Average coverage                           | >=30X      | >=20X    | >=40X    | >=40X    | >=20X         | >=40X        | >=20X       |
| De novo assembly: Seq. length (Mbp)        | ~4.3-5.2   | ~2.7-3.2 | ~4.5-5.9 | ~4.0-5.0 | ~1.5-1.9      | ~4.8-5.5     | ~4-5        |
| De novo assembly: no. contigs              | <=300      | <=300    | <=500    | <=650    | <=300         | <=300        | <=500       |



# Herramienta de control de calidad del ensamblaje: QUAST

Longitud del genoma (longitud total de todos los contigs)



**Debería estar cerca de lo esperado para los taxones**


*E. cloacae*: Aproximadamente 3.6 a 4.6 millones de pares de bases de longitud

MTB: Aproximadamente 4,4 millones bp

| A                                          | B                 | C               | D              | E               | F                    | G                   | H                  |
|--------------------------------------------|-------------------|-----------------|----------------|-----------------|----------------------|---------------------|--------------------|
| Quality metric                             | <i>Salmonella</i> | <i>Listeria</i> | <i>E. coli</i> | <i>Shigella</i> | <i>Campylobacter</i> | <i>Vibrio para.</i> | <i>Cronobacter</i> |
| Average read quality Q score for R1 and R2 | >=30              | >=30            | >=30           | >=30            | >=30                 | >=30                | >=30               |
| Average coverage                           | >=30X             | >=20X           | >=40X          | >=40X           | >=20X                | >=40X               | >=20X              |
| De novo assembly: Seq. length (Mbp)        | ~4.3-5.2          | ~2.7-3.2        | ~4.5-5.9       | ~4.0-5.0        | ~1.5-1.9             | ~4.8-5.5            | ~4-5               |
| De novo assembly: no. contigs              | <=300             | <=300           | <=500          | <=650           | <=300                | <=300               | <=500              |

# Herramienta de control de calidad del ensamblaje: QUAST

Valor N50



## Más grande es mejor

Longitud del contig más corto necesario cuando se cubre el 50% de la longitud total del genoma utilizando el menor número de contigs (los más largos)

| Quality Metric        | Listeria  | Campylobacter | STEC      | Salmonella |
|-----------------------|-----------|---------------|-----------|------------|
| De novo assembly: N50 | > 200,000 | > 100,000     | > 100,000 | > 200,000  |

# Herramienta de control de calidad del ensamblaje: QUAST

GC %

ATGCCAACAGTTCTGACTGA

$$9/20 = 45\%$$

*Salmonella*: 51 – 53 %.  
*Acinetobacter*: 38 -47%  
MTB: Alto contenido de G+C de  
alrededor del 65,6%.

Las diferentes especies bacterianas tienen diferentes porcentajes medios de GC

# Control de calidad del ensamblaje

## Métricas de calidad de los ensamblajes genómicos

**Longitud del ensamblaje:** Número de bases incluidas en el ensamblaje final

**Número de contigs:** número de secuencias contiguas derivadas de datos de lecturas superpuestas

| assembly_length | combined_mean_n_q_clean | combined_mean_readlength_clean | est_coverage_clean | n50_value | number_contigs | quast_gc_percent | quast_version |
|-----------------|-------------------------|--------------------------------|--------------------|-----------|----------------|------------------|---------------|
| 4354948         | 35.54                   | 223.97                         | 81.97              | 123076    | 94             | 65.58            | QUAST v5.0.2  |
| 4320428         | 35.68                   | 223.06                         | 67.21              | 125363    | 95             | 65.57            | QUAST v5.0.2  |
| 4289856         | 35.29                   | 205.86                         | 42.53              | 68105     | 147            | 65.4             | QUAST v5.0.2  |
| 4318682         | 35.68                   | 223.24                         | 74.04              | 141148    | 98             | 65.57            | QUAST v5.0.2  |
| 4313575         | 35.46                   | 221.44                         | 94.12              | 125363    | 103            | 65.55            | QUAST v5.0.2  |
| 4301866         | 35.56                   | 222.98                         | 70.63              | 103660    | 110            | 65.5             | QUAST v5.0.2  |

# Herramienta de control de calidad del ensamblaje: BUSCO

Evaluación comparativa de ortólogos universales de copia única (Benchmarking Universal Single-Copy Orthologs)

- Evalúa la presencia de genes que se espera encontrar una vez en cada genoma ("ortólogos de copia única")
- La base de datos BUSCO **debe** coincidir con los taxones del genoma para que los resultados sean válidos.

BUSCO evalúa la calidad de un genoma buscando genes esenciales y conservados que deberían estar presentes en todas las especies de un linaje. Si la mayoría de estos genes aparecen completos y en copia única, significa que el genoma está completo y bien ensamblado. Si faltan muchos o aparecen duplicados, indica problemas de ensamblaje, fragmentación o contaminación.

# Herramienta de control de calidad del ensamblaje: BUSCO Salidas

Resultados BUSCO, por ejemplo

**C:99.1%[S:98.9%,D:0.2%],F:0.0%,M:0.9%,n:440**

- **Completo (C)** - los genes se consideran "completos" cuando sus longitudes están dentro de dos desviaciones estándar de la longitud media del grupo BUSCO.
- **Copia única (S)** - genes que están completos y sólo tienen una copia.
- **Duplicados (D)** - genes que están completos y tienen más de una copia.
- **Fragmentados (F)** - genes recuperados sólo parcialmente.
- **Desaparecidos (M)** - genes que no se han recuperado en absoluto.
- **Número de genes examinados (n)** - número de genes examinados.

| busco_database                       | busco_results                               | busco_version |
|--------------------------------------|---------------------------------------------|---------------|
| corynebacteriales_odb10 (2024-01-08) | C:99.6%[S:99.1%,D:0.5%],F:0.0%,M:0.4%,n:743 | BUSCO 5.7.1   |
| corynebacteriales_odb10 (2024-01-08) | C:99.6%[S:99.3%,D:0.3%],F:0.0%,M:0.4%,n:743 | BUSCO 5.7.1   |
| corynebacteriales_odb10 (2024-01-08) | C:99.6%[S:99.1%,D:0.5%],F:0.0%,M:0.4%,n:743 | BUSCO 5.7.1   |
| corynebacteriales_odb10 (2024-01-08) | C:99.6%[S:99.3%,D:0.3%],F:0.0%,M:0.4%,n:743 | BUSCO 5.7.1   |
| corynebacteriales_odb10 (2024-01-08) | C:99.6%[S:99.3%,D:0.3%],F:0.0%,M:0.4%,n:743 | BUSCO 5.7.1   |

# Evaluación de las métricas de control de calidad

- El flujo de trabajo de TheiaProk proporciona métricas de CC
- Es necesario evaluar las métricas de control de calidad con respecto a las expectativas biológicas razonables para el organismo
  - “Umbrales de control de calidad”

# ¿Qué umbrales de control de calidad debemos utilizar?

---

NO se han definido umbrales de calidad exhaustivos para la mayoría de los patógenos 😞

---

Se dispone de orientación para algunos patógenos de algunos programas, por ejemplo, PulseNet 😊

---

La comunidad de salud pública está trabajando en más orientaciones de CC 😄

---

Los umbrales pueden tener que ser autodefinidos

---

**Los umbrales serán erróneos, a veces**

---

**Así que, en otras palabras: ....¡depende!**



# Tras comparar las métricas de control de calidad con los umbrales...

- Continúa analizando muestras y utiliza sus resultados únicamente si han PASADO el control de calidad


# Soluciones para los fallos de control de calidad

|    |                                         |                                                                                                 |                                                                                                        |
|----|-----------------------------------------|-------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------|
| 01 | <b>Compleitud</b><br>(Completeness)     | ¿Está representado todo el genoma en los datos de la secuencia y el ensamblaje?                 | Secuenciar a mayor profundidad                                                                         |
| 02 | <b>Contigüidad</b><br>(Contiguity)      | ¿Hasta qué punto está fragmentado el ensamblaje?                                                | Utilizar longitudes de lectura más largas                                                              |
| 03 | <b>Corrección</b><br>(Correctness)      | ¿Es correcto el ensamblaje a nivel de cada base y están correctamente ensambladas las lecturas? | Secuenciar a mayor profundidad/reducir el número de lecturas/utilizar secuenciación de mayor precisión |
| 04 | <b>Contaminación</b><br>(Contamination) | ¿Proviene (suficientes) lecturas del organismo objetivo?                                        | Aislar y secuenciar de nuevo                                                                           |


# Fases del análisis bioinformático

## Análisis bioinformático (análisis de muestras)


- **Pre procesamiento de datos:** Eliminar las lecturas de baja calidad, los adaptadores y recorte de secuencias (limpieza de lecturas)
- **Ensamblaje De Novo** (si procede): Ensamblaje de secuencias en contigs más largos sin genoma de referencia
- **Identificación taxonómica:** Identificar el género y la especie a la que pertenece la muestra
- **Anotación:** Anotación de variantes genéticas y predicción de su impacto funcional
- **Caracterización genómica:** Identificar las características genómicas que confieren cualidades fenotípicas como la resistencia a los antibióticos



# Flujos de trabajo de TheiaProk (v2.0.1)



**Identificación taxonómica:** Identificar el género y la especie a la que pertenece la muestra




**GAMBIT, ANI, kmerfinder** son herramientas de identificación de taxones


# Asignación de taxones

## Herramientas de identificación taxonómica:


- GAMBIT
  - herramienta de identificación de taxones basada en kmer
  - Identificación rápida y precisa de géneros y especies
- Identidad nucleotídica media (ANI)
  - Comparación de la longitud completa del genoma de consulta
  - Utiliza una base de datos de genomas de referencia



# Asignación taxonómica *In Silico*: GAMBIT



# Asignación taxonómica *In Silico*: ANI



# Asignación de taxones

| Herramienta                                                                    | Fundamento / Principio                                                                                                                                                                          | Tipo de análisis                                                                                       | Ventajas                                                                                                  | Limitaciones                                                                                                                      |
|--------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------|
| <b>ANI (Average Nucleotide Identity)</b>                                       | Calcula el porcentaje promedio de identidad nucleotídica entre el genoma de la muestra y genomas de referencia. Evalúa la similitud global del ADN a nivel de todo el genoma.                   | Comparación genómica global basada en alineamientos de secuencias.                                     | Alta precisión para diferenciar especies cercanas (<95 % ANI suele indicar especie diferente).            | Requiere genomas completos o ensamblajes de buena calidad; sensible a contaminaciones o ensamblajes fragmentados.                 |
| <b>GAMBIT (Genomic Approximation Method for Bacterial Identification Tool)</b> | Utiliza perfiles genómicos basados en k-mers + hashing y compara contra una base de datos de referencias codificadas para predecir la identidad taxonómica calculando distancias entre genomas. | Basado en similitud de patrones de k-mers+ hashing + jaccard distances (fragmentos cortos del genoma). | Rápido, útil con datos crudos (FASTQ) o ensamblados. Permite una estimación inicial del género o especie. | Puede asignar especies incorrectas si las bases de datos no contienen genomas representativos o si las especies son muy cercanas. |
| <b>KmerFinder</b>                                                              | Compara frecuencias de k-mers (fragmentos de longitud fija, típicamente 16-20 pb) del genoma de la muestra contra genomas de referencia. Calcula el porcentaje de coincidencia.                 | Análisis de similitud genómica por conteo de k-mers.                                                   | Rápido, independiente de alineamiento, y eficiente con datos de lectura corta.                            | No distingue bien especies con genomas muy similares depende de la calidad y cobertura de las secuencias.                         |



# Asignación de taxones

Cuadro 1. Identificación a nivel de especie de la secuencia obtenida por cuatro herramientas bioinformáticas diferentes.

| Muestra | Herramienta bioinformática |                        |                            |                          |
|---------|----------------------------|------------------------|----------------------------|--------------------------|
|         | ani_top_species_match      | gambit_predicted_taxon | kmerfinder_top_hit         | Ribosomal MLST           |
| 858992  | <i>Brucella microti</i>    | <i>Brucella suis</i>   | <i>Brucella melitensis</i> | <i>Brucella neotomae</i> |


Cuadro 1. Identificación a nivel de especie de las secuencias obtenidas por cuatro herramientas bioinformáticas diferentes.

| Muestra | Herramienta bioinformática |                            |                        |                            |
|---------|----------------------------|----------------------------|------------------------|----------------------------|
|         | ani_top_species_match      | gambit_predicted_taxon     | kmerfinder_top_hit     | Ribosomal MLST             |
| 861268  | <i>Vibrio cholerae</i>     | <i>Vibrio paracholerae</i> | <i>Vibrio cholerae</i> | <i>Vibrio paracholerae</i> |
| 862170  | <i>Vibrio cholerae</i>     | <i>Vibrio paracholerae</i> | <i>Vibrio cholerae</i> | <i>Vibrio paracholerae</i> |

# Fases del análisis bioinformático

## Análisis bioinformático (análisis de muestras)


- **Pre procesamiento de datos:** Eliminar las lecturas de baja calidad, los adaptadores y recorte de secuencias (limpieza de lecturas)
- **Ensamblaje De Novo** (si procede): Ensamblaje de secuencias en contigs más largos sin genoma de referencia
- **Identificación taxonómica:** Identificar el género y la especie a la que pertenece la muestra
- **Anotación:** Anotación de variantes genéticas y predicción de su impacto funcional
- **Caracterización genómica:** Identificar las características genómicas que confieren cualidades fenotípicas como la resistencia a los antibióticos



# Anotación

## Anotación del genoma


- Prokka/Bacta
  - Proporcionar información detallada sobre genes, secuencias codificantes y elementos reguladores en genomas microbianos
  - Predecir funciones génicas
  - Identificar fenotipos potencialmente patógenos




# Fases del análisis bioinformático

## Análisis bioinformático

- **Pre procesamiento de datos:** Eliminar las lecturas de baja calidad, los adaptadores y recorte de secuencias (limpieza de lecturas)
- **Ensamblaje De Novo** (si procede): Ensamblaje de secuencias en contigs más largos sin genoma de referencia
- **Identificación taxonómica:** Identificar el género y la especie a la que pertenece la muestra
- **Anotación:** Anotación de variantes genéticas y predicción de su impacto funcional
- **Caracterización genómica:** Identificar las características genómicas que confieren cualidades fenotípicas como la resistencia a los antibióticos



# Flujos de trabajo de TheiaProk (v2.0.1)



## Caracterización genómica de TheiaProk

Tipificación de secuencias de múltiples locus ("MLST")


AMR - antibióticos, metales, biocidas, desinfectantes, virulencia, estrés a partir de genes, SNPs, INDELs, MNPs (AMRFinderPlus/ResFinder)

Identificación de plásmidos a partir de genes rep (PlasmidFinder)

Anotaciones de genes/características (Prokka o Bakta, herramientas en el subflujo de trabajo específico de taxones)

Serotipo (varios en flujos de trabajo específicos de taxones)

# Flujos de trabajo de TheiaProk (v2.0.1)



# ¿Qué es MLST?

Tipificación **por** secuenciación **de** múltiples **LOCUS** (**M**ulti**L**ocus **S**equencing **T**yping)

- Forma de subtipificar taxones, normalmente especies, para comprender la estructura de la población
- Describe la estructura de la población; no refleja el fenotipo
- Para epidemiología global o a largo plazo
- Propuesto por primera vez en 1998, mediante PCR y secuenciación de Sanger

# ¿Qué es MLST?

Esquemas de **Tipificación** por Secuenciación de Múltiples Locus

- A cada alelo distinto de cada locus se le asigna un número arbitrario
- A cada perfil alélico se le asigna un número ST arbitrario

| ST | Pas <sub>cpn60</sub> | Pas <sub>fusA</sub> | Pas <sub>gltA</sub> | Pas <sub>pyrG</sub> | Pas <sub>recA</sub> | Pas <sub>rplB</sub> | Pas <sub>rpoB</sub> |
|----|----------------------|---------------------|---------------------|---------------------|---------------------|---------------------|---------------------|
| 1  | 1                    | 1                   | 1                   | 1                   | 5                   | 1                   | 1                   |
| 2  | 2                    | 2                   | 2                   | 2                   | 2                   | 2                   | 2                   |
| 3  | 3                    | 3                   | 2                   | 2                   | 3                   | 1                   | 3                   |
| 4  | 1                    | 3                   | 3                   | 2                   | 4                   | 1                   | 4                   |
| 5  | 4                    | 1                   | 2                   | 2                   | 4                   | 1                   | 5                   |
| 6  | 5                    | 4                   | 4                   | 1                   | 3                   | 3                   | 4                   |
| 7  | 1                    | 1                   | 1                   | 2                   | 5                   | 1                   | 1                   |
| 8  | 1                    | 1                   | 1                   | 1                   | 1                   | 1                   | 1                   |
| 9  | 3                    | 1                   | 5                   | 3                   | 6                   | 1                   | 3                   |
| 10 | 1                    | 3                   | 2                   | 1                   | 4                   | 4                   | 4                   |



# ¿Qué es MLST? En la práctica

cpn60

fusA

gltA

pyrG

recA

rplB

rpoB

[illegible]

1949352  
 CAACCTCACTGTTGGTGGTGTGTCACATGGAACCTCCGAGAGTGCACAACTGATGTTG  
 ATAACTGCTCTTTCTTATATGCAAAAGGAGATGCTTCTGTTGTTTGGAGACACATG  
 GAGAGATTTGAAATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTG  
 GTGTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTG  
 GATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTG  
 CATATGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTG  
 GATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTG  
 JCTTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTGATGTTG

[illegible]

ifex\_hspc\_2  
CAATCCACATCTGGTGGTCTTTCGCGATTTCGACCTCTTAAAGCTCAAAAGATGTTT  
ATTACCTGCTCTTTTCTATGCTCCCAAGAGGATGATCTCTCTTTCTTTGAGAACCTGAG  
CGAGAAATGATTAATTAATTTTATTTTATCTGCTCTTTTATTTCTTTCTTTCTGATTTTAAAGAT  
CTGTGACTGATCTTTCTGACAGGCGACTCTGCTCTAGTAAGATGGGACTTTTACAGC  
GATTTGCTTTTCTTCTTCTGATCAAGATGATTTTCTATATTTCTGCTCTTTAAAGATTTAAAT  
CAATTAAGGCTTTTCTCTGAGCAAGATGATTTCTTTCTGCTGCTCTTTCTTCTGCTCTTT  
GAGACATCTGACCAAGCTCTGCTGCTCACTGCTTTAAATCTGCTCTGAGGCTGCTCTCT  
ACCTTTCTGCTGAGATGAAGCTGCTTTTGTGAGTGGCTGAT

[illegible]

5'-GAGCAGCAGTATGCTGCTGCTTGTGCGATTTGAGACCTCTGAGGCTGCAAGCTGATGTT  
 ATACGACGCTTTTCTATGCTGCTCAAGAGCGAGGAGCTCTGCTGTTTCTTGAGGACAGCTG  
 CAGAGAGTTTAAAGATGTTGTTTATGCTGATGTTGTTTAAAGTATGTTGTTGTTGTTGTTGTTG  
 TTGTGATCTGTGATTGAGAGAGCGAGCTCTGCTGTTGTTGTTGTTGTTGTTGTTGTTGTTGTTG  
 GAATGTTGTTTCTTCTTCTGTTGTTGTTGTTGTTGTTGTTGTTGTTGTTGTTGTTGTTGTTGTTG  
 CATTAGAGCTTTCTTGAGAGAGAGAGTTGTTGTTGTTGTTGTTGTTGTTGTTGTTGTTGTTGTTG  
 TTTGAGCTGCTGCTGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAG  
 AGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAGAG

[illegible]

# Pub MLST

[illegible][illegible][illegible]

*JPhar\_novel\_3*

[illegible][illegible][illegible]

3

41

6

6

3

4

5

**ST = 154**

# MLST con la herramienta MLST de Torsten Seemann

- Utiliza una base de datos para identificar alelos y ST que han sido previamente asignados por PubMLST
- La base de datos es una captura reciente de todo lo que había en la base de datos PubMLST en una fecha determinada
- No asigna nuevos números de alelo o ST

| ts_mlst_allelic_profile                                          | ts_mlst_predicted_st | ts_mlst_pubmlst_scheme | ts_mlst_version |
|------------------------------------------------------------------|----------------------|------------------------|-----------------|
| S14Z(17),L35(15),S19(20),L19(19),S12(20),S8(18),L16(22),S7(19)   | ST215                | mycobacteria_2         | 2.23.0          |
| S14Z(17),L35(15),S19(20),L19(19),S12(20),S8(18),L16(22),S7(19)   | ST215                | mycobacteria_2         | 2.23.0          |
| S14Z(140),L35(15),S19(20),L19(19),S12(20),S8(~18),L16(22),S7(19) | No ST predicted      | mycobacteria_2         | 2.23.0          |
| S14Z(17),L35(15),S19(20),L19(19),S12(20),S8(18),L16(22),S7(19)   | ST215                | mycobacteria_2         | 2.23.0          |
| S14Z(17),L35(15),S19(20),L19(19),S12(20),S8(18),L16(22),S7(19)   | ST215                | mycobacteria_2         | 2.23.0          |
| S14Z(17),L35(15),S19(20),L19(19),S12(20),S8(18),L16(22),S7(19)   | ST215                | mycobacteria_2         | 2.23.0          |


# MLST de TheiaProk      Salidas

| OR_PHL_Acinetob... ↓ ⓘ | ts_mlst_novel_alleles ⓘ                             | ts_mlst_predicted_st ⓘ | ts_mlst_pubmlst_scheme ⓘ | ts_mlst_results ⓘ                       | ts_mlst_version ⓘ |
|------------------------|-----------------------------------------------------|------------------------|--------------------------|-----------------------------------------|-------------------|
| 18011703594            |                                                     | ST154                  | abaumannii_2             | <a href="#">18011703594_ts_mlst.tsv</a> | 2.23.0            |
| 18012505923            |                                                     | ST2                    | abaumannii_2             | <a href="#">18012505923_ts_mlst.tsv</a> | 2.23.0            |
| 18021403312            |                                                     | ST2                    | abaumannii_2             | <a href="#">18021403312_ts_mlst.tsv</a> | 2.23.0            |
| 18022104409            | <a href="#">18022104409_novel_mlst_alleles.f...</a> | No ST predicted        | abaumannii_2             | <a href="#">18022104409_ts_mlst.tsv</a> | 2.23.0            |
| 18022304984            |                                                     | No ST predicted        | abaumannii_2             | <a href="#">18022304984_ts_mlst.tsv</a> | 2.23.0            |
| 18022705617            |                                                     | ST2                    | abaumannii_2             | <a href="#">18022705617_ts_mlst.tsv</a> | 2.23.0            |
| 18022705618            |                                                     | ST2                    | abaumannii_2             | <a href="#">18022705618_ts_mlst.tsv</a> | 2.23.0            |
| 18022705619            |                                                     | No ST predicted        | abaumannii_2             | <a href="#">18022705619_ts_mlst.tsv</a> | 2.23.0            |
| 18022805979            |                                                     | No ST predicted        | abaumannii_2             | <a href="#">18022805979_ts_mlst.tsv</a> | 2.23.0            |
| 18022806324            |                                                     | ST2                    | abaumannii_2             | <a href="#">18022806324_ts_mlst.tsv</a> | 2.23.0            |
| 18041102359            |                                                     | ST570                  | abaumannii_2             | <a href="#">18041102359_ts_mlst.tsv</a> | 2.23.0            |


# MLST en epidemiología

- Para vigilancia temporal

Distribución de secuenciotipos de *C. jejuni*, aislados de muestras clínicas confirmados por secuenciación de genoma completo.  
Enero – Diciembre, 2025. n = 34




# Flujos de trabajo de TheiaProk (v2.0.1)



# Umbrales para la identificación de ARGs

(genes de resistencia a los antibióticos)



La presencia de un gen que codifica una proteína ARG o de una mutación causante de resistencia **no indica necesariamente que el aislado portador del gen sea resistente** al antibiótico correspondiente.

# Caracterización genómica: AMRFinderPlus

- Desarrollado por el NCBI
- Identifica **genes y mutaciones puntuales** asociados con la resistencia antimicrobiana, la virulencia y el estrés
- **Valores predeterminados de TheiaProk:**
  - argumentos por defecto de la herramienta CLI AMRFinderPlus
  - el argumento del organismo se selecciona en función de la predicción de GAMBIT, si corresponde

# Caracterización genómica: AMRFinderPlus

- **Salidas:**

- Determinantes de AMR, estrés y virulencia predichos
- Clases previstas de farmacorresistencia basadas en los determinantes de AMR detectados

| pni_sample_id | amrfinderplus_version | amrfinderplus_db_version | amrfinderplus_all_report                    | amrfinderplus_amr_classes              | amrfinderplus_amr_genes               | amrfinderplus_stress_genes |
|---------------|-----------------------|--------------------------|---------------------------------------------|----------------------------------------|---------------------------------------|----------------------------|
| MUESTRA_01    | 3.10.42               | 2022-10-11.2             | <a href="#">sample_01_amrfinder_all.tsv</a> | BETA-LACTAM,COLISTIN,EFFLUX,FOSFOMYCIN | gipT_E448K,mdtM,blaEC,acrF,pmrB_Y358N | ymgB,terD,terZ,terW        |
| MUESTRA_02    | 3.10.42               | 2022-10-11.2             | <a href="#">sample_02_amrfinder_all.tsv</a> | BETA-LACTAM,COLISTIN,EFFLUX,FOSFOMYCIN | gipT_E448K,acrF,blaEC,mdtM,pmrB_Y358N | ymgB,terD,terZ,terW        |
| MUESTRA_03    | 3.10.42               | 2022-10-11.2             | <a href="#">sample_03_amrfinder_all.tsv</a> | BETA-LACTAM,COLISTIN,EFFLUX,FOSFOMYCIN | gipT_E448K,blaEC,acrF,mdtM,pmrB_Y358N | ymgB,terD,terZ,terW        |



# Otras predicciones de AMR en TheiaProk


## ResFinder (opcional)

- Identifica ARGs pero no mutaciones puntuales
- Utiliza una base de datos subyacente y umbrales diferentes para identificar genes


## Herramientas específicas de taxones, p. ej.

- TB-profiler
- Kleborate

# Flujos de trabajo de TheiaProk (v2.0.1)



# Flujos de trabajo de TheiaProk (v2.0.1)



# Tareas específicas de los taxones de TheiaProk

- *Acinetobacter baumannii*
- *Escherichia* or *Shigella* spp
- *Haemophilus influenzae*
- *Klebsiella* spp
- *Legionella pneumophila*
- *Listeria monocytogenes*
- *Mycobacterium tuberculosis*
- *Neisseria* spp
- *Pseudomonas aeruginosa*
- *Salmonella* spp
- *Staphylococcus aureus*
- *Streptococcus pneumoniae*
- *Streptococcus pyogenes*
- *Vibrio* spp

- Los flujos de trabajo de TheiaProk activan automáticamente **subflujos de trabajo específicos de taxones** tras la identificación de los taxones relevantes mediante GAMBIT.

# SISTR (Salmonella In Silico Typing Resource)

## Primary results output ( `-o sistr-results` )

SISTR supports various text output formats specified by the `-f` option with `json` being the default.

## JSON results output ( `-f json` ):

```
[
  {
    "serovar_cgmlst": "Typhimurium",
    "cgmlst_matching_alleles": 327,
    "h1": "i",
    "serovar_antigen": "Typhimurium",
    "cgmlst_distance": 0.009090909090909038,
    "h2": "1,2",
    "cgmlst_genome_match": "LT2",
    "cgmlst_ST": 660408169,
    "serovar": "Typhimurium",
    "fasta_filepath": "/full/path/to/LT2.fasta",
    "genome": "LT2",
    "serogroup": "B",
    "qc_messages": "",
    "qc_status": "PASS",
    "o_antigen": "1,4,[5],12",
    "cgmlst_subspecies": "enterica"
  }
]
```


- SISTR realiza la predicción del serotipo de *Salmonella* spp. utilizando **alelos de genes de antígeno y genes cgMLST**.
- En TheiaProk, SISTR se ejecuta a partir del ensamblaje y utiliza la configuración de datos predeterminada (alelos "centroides" más pequeños o alelos representativos en lugar del conjunto completo de alelos cgMLST).
- También ejecuta un modo de control de calidad para determinar el nivel de confianza en la predicción del serotipo.

he *Salmonella* In Silico Typing Resource (SISTR): an open web-accessible tool for rapidly typing and subtyping draft *Salmonella* genome assemblies. Catherine Yoshida, Peter Kruczkiewicz, Chad R. Laing, Erika J. Lingohr, Victor P.J. Gannon, John H.E. Nash, Eduardo N. Taboada. PLoS ONE 11(1): e0147101. doi: 10.1371/journal.pone.0147101

• <https://doi.org/10.1371/journal.pone.0147101>

# Genotypi

- Genotypi se activa al identificar el serotipo "Typhi" mediante SISTR o SeqSero2.
- Genotypi divide la población de *Salmonella enterica* serovar Typhi en linajes, clados y subclados detallados.
- También detecta mutaciones en las regiones determinantes de la resistencia a las quinolonas, genes de resistencia antimicrobiana adquirida, replicones de plásmidos y subtipos del plásmido IncHI1, asociado a la multirresistencia.
- TheiaProk utiliza como entrada las lecturas de secuenciación crudas.



# Formas de caracterizar los genomas

- Puede haber múltiples herramientas para una determinada tarea de genotipado (por ejemplo, serotipado de Salmonella) que empleen un método diferente y/o diferentes bases de datos.
  - Diferentes pros, contras y exactitud
- **Los resultados concordantes** de distintos métodos pueden ayudar a verificar los resultados del genotipado.
- **Los resultados discordantes** de distintos métodos deberán investigarse con más detalle.