



Introducción a la epidemiología genómica y filogenética

Taller de secuenciación genómica y análisis bioinformático para patógenos bacterianos con enfoque una salud.

Laboratorio de genómica y biología molecular, CNRIMA. Inciensa

Junio, 2026

Epidemiología genómica

Epidemiología

- Estudio de la **distribución, frecuencia** y factores determinantes de las enfermedades existentes **en poblaciones humanas definidas** y la **aplicación** de este estudio para controlar los problemas de salud

Epidemiología genómica


- Uso de datos genómicos de patógenos para determinar la **distribución y propagación** de una enfermedad infecciosa **en una población específica** y la **aplicación** de esta información para controlar problemas de salud

Muchos estudios destacan la **utilidad de la epidemiología genómica frente a los métodos tradicionales** para la vigilancia de patógenos y la investigación de brotes

Epidemiología genómica


La epidemiología genómica comprende:

- Vigilancia y tipificación de patógenos en el tiempo y el espacio
- Historia evolutiva (filogenética)




La epidemiología genómica facilita...

- La identificación de introducciones de nuevos patógenos
- La comprensión de la dinámica de transmisión
- La comprensión de la evolución de los patógenos




Proceso epidémico

Todos los casos de la cadena de transmisión representados en el tiempo




Individuos muestreados

Secuencias genómicas disponibles sólo para algunos casos




Secuencia del genoma

Por medio de la secuencias disponibles se pueden identificar conexiones



Determinar filogenia


Estas conexiones pueden ser representadas en un árbol filogenético



Usando la filogenética, esas relaciones se pueden visualizar como un "árbol" que siempre es una aproximación de la verdadera cadena de transmisión.

Introducción a la filogenética

¿Qué es un árbol filogenético?



1837, Charles Darwin

- **Diagrama** utilizado para representar las **relaciones ancestrales** entre genes y organismos.
- Muestra qué genes/organismos están **más estrechamente relacionados** y cuáles están más **alejados**.
- **Si está enraizado**, también muestra la dirección del proceso evolutivo a lo largo del tiempo.

Análisis filogenético en la investigación de brotes epidémicos

- Evaluación de la **relación evolutiva** de un conjunto de muestras como un indicador de la **probabilidad de transmisión** de enfermedades infecciosas
 - La secuenciación y la bioinformática ofrecen una comprensión de **alta resolución** de la relación genética

Muchos enfoques disponibles para realizar análisis filogenéticos

Construyendo árboles filogenéticos

Steps to Build a Phylogeny (Very Simplified)

FASTQ

FASTA

1. Define the objective: What evolutionary question do you want to answer?

2. Define the dataset: Select appropriate sequences based on the question.

3. Obtain sequences: Scientific articles; public databases such as NCBI, Ensembl, UniProt, GISAID.

4. Align sequences: you could use MAFFT; verify and correct alignment (Aliview).

5. Reconstruct the phylogenetic tree: Recommended software: IQ-TREE.


6. Evaluate tree reliability: Perform bootstrap or other support analyses; interpret node support values.


7. Visualize and export the tree: Tools like FigTree, iTOL, Dendroscope; adjust labels, colors, and branches.

8. Interpret results: Relate findings to the original question and available epidemiological information.

9. Communicate the results.

Tree scale: 0.1







Tipo de actividad:
Secuenciación de genoma completo y análisis bioinformático de las muestras Inciens # 861268 y # 862170 correspondientes a cepas bacterianas identificadas como *V. cholerae*, aisladas a partir de una muestra clínica de heces de paciente y de una muestra de licuado de verduras respectivamente, ambas muestras estaban asociadas a un evento de enfermedad diarreica aguda ocurrido en el centro de cuido Fundación [redacted] a finales de abril del año en 2025.

Cuadro 1. Identificación a nivel de especie de las secuencias obtenidas por cuatro herramientas bioinformáticas diferentes.

Muestra	Herramienta bioinformática			
	ani_top_species_match	gambit_predicted_taxon	kmerfinder_top_hit	Ribosomal MLST
861268	<i>Vibrio_cholerae</i>	<i>Vibrio paracholerae</i>	<i>Vibrio cholerae</i>	<i>Vibrio paracholerae</i>
862170	<i>Vibrio_cholerae</i>	<i>Vibrio paracholerae</i>	<i>Vibrio cholerae</i>	<i>Vibrio paracholerae</i>

- ¿La muestra del paciente y de [redacted] alimento están genéticamente relacionadas entre sí?.
- ¿Cuál es la identificación a nivel de especie del aislamiento?



Population Analysis of *Vibrio cholerae* in Aquatic Reservoirs Reveals a Novel Sister Species (*Vibrio paracholerae* sp. nov.) with a History of Association with Humans

Mohammad Tarekul Islam ^a, Tania Nasreen ^a, Paul C. Kirchberger ^b, Kevin Y. H. Liang ^a,
Fabini D. Orata ^a, Fatema-Tuz Johura ^c, Nora A. S. Hussain ^a, Monica S. Im ^d, Cheryl L. Tarr ^d,
Munirul Alam ^c, Yann F. Boucher ^{a,e}

^aDepartment of Biological Sciences, University of Alberta, Edmonton, Alberta, Canada

^bDepartment of Integrative Biology, University of Texas at Austin, Austin, Texas, USA

^cInfectious Diseases Division, International Centre for Diarrheal Disease Research, Bangladesh (icddr), Dhaka, Bangladesh

^dNational Center for Emerging and Zoonotic Infectious Diseases, Centers for Disease Control and Prevention, Atlanta, Georgia, USA

^eSaw Swee Hock School of Public Health, National University of Singapore, Singapore




FIG 5 Whole-genome phylogenetic tree of *Vibrio paracholerae* along with its closest relatives. The maximum likelihood phylogenetic tree was constructed from the core genome alignment of ≈ 2.1 Mbp using the GTR gamma substitution model. Corresponding nodes with relevant bootstrap support over 70% from the 100 replicates were indicated with an asterisk (*). The scale bar represents nucleotide substitutions per site.



¿Qué secuencias deben incluirse en un árbol filogenético?

- Las secuencias que debes incluir en un árbol filogenético dependen de la pregunta epidemiológica que estés tratando de responder:

- ¿Estas secuencias representan un brote?

Incluir todas las secuencias de alta calidad de un ST específico

- ¿Estas secuencias forman parte de un brote en curso?



Incluir todas las secuencias de alta calidad del genotipo conocido, además de algunas secuencias que se sabe que son parte del brote

- Esta secuencia pertenece a un genotipo nuevo?


Incluir secuencias de alta calidad de múltiples genotipos

- Sin pregunta, simplemente descriptivo


Incluir todas las secuencias de alta calidad de la especie que estás tratando de describir



✓ Positional homology



Non-aligned sequences



Aligned sequences

- Los nts o AA encontrados en una posición (columna) en las secuencias se consideran descendientes de un sitio ancestral común (homólogo).
- Todos los métodos intentan maximizar las coincidencias / similitudes y minimizar las discrepancias / diferencias entre secuencias.
- Diferentes programas buscan la "mejor" alineación a través de diferentes métodos.

Programas para construir alineamientos



ClustalW/X:
Progressive
alignment.

Muscle: Iterative
method.



MAFFT: multiple
methods.

T-Coffee



PROBCONS

ProbCons

Probalign




Alineamiento de secuencias múltiples

Multiple sequence alignment (MSA)

Genetic relatedness (SNP differences)

	2016K-0438	PNUSAS010651	PNUSAS011968	PNUSAS013510	PNUSAS013903	PNUSAS013904	PNUSAS013905
2016K-0438	0	35	37	36	25	28	26
PNUSAS010651	35	0	2	41	31	35	34
PNUSAS011968	37	2	0	41	30	34	33
PNUSAS013510	36	41	41	0	28	33	30
PNUSAS013903	25	31	30	28	0	1	1
PNUSAS013904	28	35	34	33	1	0	2
PNUSAS013905	26	34	33	30	1	2	0


Phylogenetic trees



Matrices de SNP

- Una matriz de SNP es otra forma de visualizar las diferencias entre secuencias de genomas completos
- En lugar de tener la divergencia entre muestras mostrada como longitudes de rama, una matriz de SNP te dará el número de SNP que diferencian cada par de muestras ("matriz de SNP por pares")

	S1	S2	S3	S4	S5	S6	S7	S8	S9	S10	S11	S12	S13	S14	S15	S16	S17	S18	S19	S20	
S1	0	0	0	0	0	0	0	2	2	3	3	8	5	6	6	1	1	2	2	2	1
S2	0	0	0	0	0	0	0	2	2	3	3	8	5	6	6	1	1	2	2	2	1
S3	0	0	0	0	0	0	0	2	2	3	3	8	5	6	6	1	1	2	2	2	1
S4	0	0	0	0	0	0	0	2	2	3	3	8	5	6	6	1	1	2	2	2	1
S5	0	0	0	0	0	0	0	2	2	3	3	8	5	6	6	1	1	2	2	2	1
S6	0	0	0	0	0	0	0	2	2	3	3	8	5	6	6	1	1	2	2	2	1
S7	2	2	2	2	2	2	0	2	3	3	8	5	6	6	1	1	0	0	0	1	
S8	2	2	2	2	2	2	2	0	1	1	6	3	4	4	1	1	2	2	2	3	
S9	3	3	3	3	3	3	3	1	0	0	5	2	3	3	2	2	3	3	3	4	
S10	3	3	3	3	3	3	3	1	0	0	5	2	3	3	2	2	3	3	3	4	
S11	8	8	8	8	8	8	8	6	5	5	0	3	4	4	7	7	8	8	8	9	
S12	5	5	5	5	5	5	5	3	2	2	3	0	1	1	4	4	5	5	5	6	
S13	6	6	6	6	6	6	6	4	3	3	4	1	0	0	5	5	6	6	6	7	
S14	6	6	6	6	6	6	6	4	3	3	4	1	0	0	5	5	6	6	6	7	
S15	1	1	1	1	1	1	1	1	2	2	7	4	5	5	0	0	1	1	1	2	
S16	1	1	1	1	1	1	1	1	2	2	7	4	5	5	0	0	1	1	1	2	
S17	2	2	2	2	2	2	0	2	3	3	8	5	6	6	1	1	0	0	0	1	
S18	2	2	2	2	2	2	0	2	3	3	8	5	6	6	1	1	0	0	0	1	
S19	2	2	2	2	2	2	0	2	3	3	8	5	6	6	1	1	0	0	0	1	
S20	1	1	1	1	1	1	1	3	4	4	9	6	7	7	2	2	1	1	1	0	



Enfoques de análisis filogenético

Enfoque general de la filogenética


1. **Identificar las diferencias genéticas** entre las muestras de un conjunto de datos
2. **Opcional: Enmascarar** las diferencias que probablemente no procedan de relaciones ancestrales
3. **Utilizar estas diferencias para inferir relaciones evolutivas**

**Muchas maneras de hacer
cada cosa**

Análisis filogenético


1. Identificación de diferencias genéticas

- **Polimorfismo de un solo nucleótido (SNP)**
 - Identificación de variaciones nucleotídicas
- **Core/whole-genome Multilocus sequence types (cg/wgMLST)**
 - Identificación de variaciones alélicas




Unidad básica de diferencia: SNPs (polimorfismos de nucleótido único)

- SNP = Single Nucleotide Polymorphism
 - Secuencia: ATGTTCTC
 - Referencia: ATGTTGCTC
- Los SNP ocurren en todo el genoma, con frecuencia variada:




cgMLST



Análisis filogenético



2. Opcional: Enmascarar las diferencias que probablemente no se deban a relaciones ancestrales

- **Recombinación**
- **Posibles desajustes en regiones repetitivas**
- **Regiones accesorias del genoma**




Análisis filogenético

3. Inferir relaciones evolutivas





Utiliza un **modelo matemático** para predecir cómo evolucionó probablemente la secuencia e inferir el árbol

Phylogenetic analysis



Phylogenetic analysis allows us to reconstruct the evolutionary history and study the processes that gave rise to it.

3. Inferir relaciones evolutivas



MODELOS SELECCIONADOS DE EVOLUCIÓN DEL ADN UTILIZADOS A MENUDO EN FIOLOGENÉTICA MOLECULAR			
MODELO	PARÁMETROS DE INTERCAMBIABILIDAD	PARÁMETROS DE FRECUENCIA BASE	REFERENCIA
JC69 (or JC)	$a = b = c = d = e = f$	$\pi_A = \pi_C = \pi_G = \pi_T = 0.25$	Jukes and Cantor (1969) ^[29]
F81	$a = b = c = d = e = f$	all π_i values free	Felsenstein (1981) ^[32]
K2P (or K80)	$a = c = d = f$ (TRANSVERSIONES), $b = e$ (TRANSICIONES)	$\pi_A = \pi_C = \pi_G = \pi_T = 0.25$	Kimura (1980) ^[33]
HKY85	$a = c = d = f$ (TRANSVERSIONES), $b = e$ (TRANSICIONES)	all π_i VALORES LIBRES	Hasagawa et al. (1985) ^[34]
K3ST (or K81)	$a = f$ (γ TRANSVERSIONES), $c = d$ (β TRANSVERSIONES), $b = e$ (TRANSICIONES)	$\pi_A = \pi_C = \pi_G = \pi_T = 0.25$	Kimura (1981) ^[35]
TN93	$a = c = d = f$ (TRANSVERSIONES), b ($A \leftrightarrow G$ TRANSICIONES), e ($C \leftrightarrow T$ TRANSICIONES)	all π_i VALORES LIBRES	Tamura and Nei (1993) ^[36]
SYM	TODOS LOS PARÁMETROS DE INTERCAMBIABILIDAD LIBRES	$\pi_A = \pi_C = \pi_G = \pi_T = 0.25$	Zharkikh (1994) ^[37]
GTR (or REV ^[20])	TODOS LOS PARÁMETROS DE INTERCAMBIABILIDAD LIBRES	all π_i VALORES LIBRES	Tavaré (1986) ^[26]

Clases de métodos de construcción de árboles: Modelos de inferencia

PARSIMONIA


Method	Data used	Tree search	Evolutionary Model
Distance	Pairwise distance	Simple algorithm	Can be complex
Parsimony *	All sites	Mainly hill climbing	Simple
Maximum likelihood *	All sites	Hill climbing	Can be complex
Bayesian inference *	All sites (+ other info)	MCMC	Can be very complex

UPGMA, NJ


* attempt to find the BEST tree


PHYML RAxML IQ-Tree FastTree

Herramientas para
construir filogenias



Steps for phylogenetic analysis





1. Define the objective:
What evolutionary
question do you want
to answer?

2. Define the dataset:
Select appropriate
sequences based on
the question.

3. Obtain sequences:
Scientific articles;
public databases such
as NCBI, Ensembl,
UniProt, GISAID.

4. Align sequences:
you could use MAFFT;
verify and correct
alignment (Aliview).

5. Reconstruct the
phylogenetic tree:
Recommended
software: IQ-TREE.


6. Evaluate tree
reliability: Perform
bootstrap or other
support analyses;
interpret node support
values.


7. Visualize and export
the tree: Tools like
FigTree, iTOL,
Dendroscope; adjust
labels, colors, and
branches.

8. Interpret results:
Relate findings to the
original question and
available
epidemiological
information.

¿Qué tan robusto es el árbol?

- **Bootstrapping** es una técnica estadística que utiliza el **remuestreo aleatorio** de datos para determinar el error de muestreo.
- Da una idea de la "**fiabilidad**" de las ramas y los grupos.
- X número de bootstraps (réplicas remuestreadas) que se crean de sus datos de entrada (MSA)
- Normalmente ejecuta entre 100 y 1.000 bootstraps para el análisis **de ML**
- Normalmente se considera significativo cuando es superior al 70% (o 0.7 o 70/100)





1. Define the objective:
What evolutionary
question do you want
to answer?

2. Define the dataset:
Select appropriate
sequences based on
the question.

3. Obtain sequences:
Scientific articles;
public databases such
as NCBI, Ensembl,
UniProt, GISAID.

4. Align sequences:
you could use MAFFT;
verify and correct
alignment (Aliview).

5. Reconstruct the
phylogenetic tree:
Recommended
software: IQ-TREE.

6. Evaluate tree
reliability: Perform
bootstrap or other
support analyses;
interpret node support
values.

7. Visualize and export
the tree: Tools like
FigTree, iTOL,
Dendroscope; adjust
labels, colors, and
branches.

8. Interpret results:
Relate findings to the
original question and
available
epidemiological
information.

Herramientas para visualización de árboles filogenéticos

FigTree(download, free): <http://tree.bio.ed.ac.uk/software/figtree/>

Geneious(download, \$\$): <https://www.geneious.com/>

UGENE (download, free): <http://ugene.net/>

TreeView(download, free): <http://jtreeview.sourceforge.net/>

iTOL(online, free or \$\$): <https://itol.embl.de/>

ETE Toolkit (online, free): <http://etetoolkit.org/treeview/>

MicroReact(online, free): <http://microreact.org/>

FASTA

FASTA

FASTA

FASTA

1. Define the objective:
What evolutionary
question do you want
to answer?

2. Define the dataset:
Select appropriate
sequences based on
the question.

3. Obtain sequences:
Scientific articles;
public databases such
as NCBI, Ensembl,
UniProt, GISAID.

4. Align sequences:
you could use MAFFT;
verify and correct
alignment (Aliview).


5. Reconstruct the
phylogenetic tree:
Recommended
software: IQ-TREE.

6. Evaluate tree
reliability: Perform
bootstrap or other
support analyses;
interpret node support
values.

7. Visualize and export
the tree: Tools like
FigTree, iTOL,
Dendroscope; adjust
labels, colors, and
branches.

8. Interpret results:
Relate findings to the
original question and
available
epidemiological
information.

Tree scale: 0.1




Species	
■	<i>Vibrio fluvialis</i>
■	<i>Vibrio furnissii</i>
■	<i>Vibrio mimicus</i>
■	<i>Vibrio metoecus</i>
■	<i>Vibrio cholerae</i>
■	<i>Vibrio paracholerae</i>

Interpretación de árboles filogenéticos

Anatomía de un árbol filogenético

Nodos terminales (puntas/hojas): Muestra
secuenciada representada en un árbol
filogenético




Estos son todos los **nodos terminales** de este árbol filogenético

Anatomía de un árbol filogenético

Nodos internos (nodo ancestral):
Antepasado común inferido


Ancestro común para
todo el árbol



Estos son todos los
nodos internos de
este árbol filogenético

Anatomía de un árbol filogenético

Longitud de rama: Representación visual de la distancia evolutiva (número de diferencias filogenéticas)





La longitud de rama entre A and B es cero, lo que indica identidad filogenética*

La longitud de rama entre A and C es mayor, lo que indica una relación evolutiva distante

Nota: En este formato (rectangular), la **longitud de las ramas verticales** sirve estrictamente como **ayuda visual** para mejorar la claridad y la organización


La rotación de las ramas no cambia el árbol



Adapted from Robert Bear

Anatomía de un árbol filogenético

Grupo o Cluster: Término general que se refiere a un grupo de muestras con una relación evolutiva cercana




Las muestras **A y B** forman un grupo de muestras

Las muestras **D and E** forman otro grupo de muestras

Interpretación de árboles

Tipos de árbol – partes de un árbol

Topología: ordenamiento de las ramas



Interpretación de árboles


¿Cómo determinamos la raíz de un árbol?

- **Método del GRUPO EXTERNO (Outgroup)**

Lo suficientemente divergente, pero lo mas similar posible.

- **Método del PUNTO MEDIO (Midpoint rooting)**

La raíz se establece en el punto medio entre los dos taxones más divergentes.




*Dirección de la
evolución*

**La raíz permite
establecer la
dirección del
proceso evolutivo.**



Árbol SNP del Genoma Central vs Árbol SNP del Genoma Pan

- El **genoma central** de un conjunto de secuencias contiene sólo los **sitios compartidos por todas las secuencias**
 - Esto es muy útil al analizar un conjunto de secuencias donde se espera cierta diversidad (múltiples genotipos en el mismo árbol, o incluyendo/excluyendo muestras de un brote)
 - Es más rápido y menos intensivo desde el punto de vista computacional construir un árbol utilizando el genoma central
- El **pangenoma** contiene **todos los sitios** encontrados en todas las secuencias del conjunto
 - Es muy útil cuando se trata de evaluar la posible transmisión entre individuos, caracterizar un brote durante un largo periodo de tiempo o describir la estructura general de la población de un patógeno
 - El número de SNP en el pangenoma siempre será mayor que en el genoma central




Más sobre árboles del genoma central...


- Ten en cuenta que cuantas más secuencias añadidas al árbol, menos SNP se utilizarán para construirlo
- Esto sucede porque los SNP centrales (sitios SNP que todos los genomas tienen en común) son los que se utilizan para construir el árbol
 - Esto no es un problema cuando las secuencias están estrechamente relacionadas (parte de un brote) porque son muy similares
 - Esto puede convertirse en un problema con secuencias más divergentes; ¡tener cuidado al añadir secuencias de contexto al árbol!



Limitaciones de los supuestos básicos: implicaciones en la interpretación

- Las secuencias que están filogenéticamente más cerca tienen más probabilidades de compartir una asociación epidemiológica. PERO...
- No se puede suponer que las vías de transmisión (y la dirección de transmisión) reflejen la filogenia (sin otros datos)
- Los vínculos causales (por ejemplo, entre casos y exposiciones) no pueden asumirse únicamente a partir de los datos de secuencia.
- ¡Los árboles son solo una aproximación de la verdadera historia!





Resumen

- Inferir filogenias te permite **reconstruir relaciones ancestrales** y **recuperar información oculta**
- Es importante utilizar **un buen método de construcción de árboles**
- **Las longitudes de las ramas** representan distancias genéticas entre secuencias. Pueden representar tiempo en árboles temporales
- Podemos probar la fiabilidad de un árbol inferido utilizando el **remuestreo bootstrap**
- Construir un árbol es solo la mitad del desafío. El verdadero desafío es **cómo interpretar el árbol**
- Existen múltiples métodos disponibles para generar filogenias de patógenos
- Los análisis filogenéticos de árboles de cgMLST y SNP son ampliamente adoptados en salud pública
 - Ambos han demostrado una utilidad increíble para la vigilancia de patógenos y las investigaciones de brotes