

Capacitación de secuenciación genómica y análisis bioinformático

Herramientas de comparación genómica

MSc. Melany Calderón Osorno

mcaldersono@inciensa.sa.cr

Laboratorio de genómica y biología molecular

Junio, 2026



Preprocesamiento

Identificar similitudes y diferencias de distintos individuos de una misma especie para comprender la evolución.


Control de calidad

Caracterización


Comparación



Análisis a partir de lecturas



Análisis a partir de ensamblaje de novo





Análisis a partir de ensamblaje de referencia

Preprocesamiento


Control de calidad

Caracterización


Comparación



Análisis a partir de lecturas



Análisis a partir de ensamblaje de novo



Análisis a partir de ensamblaje de referencia



Prokka

Anotación genómica

Anotación estructural

Posiciones de las características genómicas a lo largo del genoma

Anotación funcional

Asignación de funciones a esas características



Prokka

Anotación genómica

Anotación estructural

Es el proceso de detectar y ubicar elementos genéticos en el genoma:

- Genes que codifican proteínas
- Regiones codificantes (ORFs)
- ARN no codificante (rRNA, tRNA, etc.)
- Elementos móviles (como fagos)



Prokka

Anotación genómica

Anotación estructural-Prodigal

Contig ATGAAATTTGGGCCCTAAATGCCCGGGTTTAA



Prokka

Anotación genómica

Anotación estructural-Prodigal

Buscar ORFs

Contig

ATGAAATTTGGGCCCTAAATGCCCGGGTTTAA



Anotación genómica

Anotación estructural-Prodigal

Buscar ORFs

Contig

ATGAAATTTGGGCCCTAAATGCCCGGGTTTAA

Codones de inicio

Codones de stop

ATG

GTG

TTG

TAA

TAG

TGA



Anotación genómica

Anotación estructural-Prodigal

Buscar ORFs

Contig

ATGAAATTTGGGGCCCT**TAA**ATGCCCGGGTTTAA

Codones de inicio

Codones de stop

ATG

GTG

TTG

TAA

TAG

TGA



Prokka

Anotación genómica

Anotación estructural-Prodigal

Buscar ORFs

Contig ATGAAATTTGGGCCCTAAATGCCCGGGTTTAA

ORF1 ATG AAA TTT GGG CCC TAA



Prokka

Anotación genómica

Anotación estructural-Prodigal

Evaluar si es un gen real

ORF1 ATG AAA TTT GGG CCC TAA

- Longitud (muy cortos suelen descartarse)
- Uso de codones (determinar si son genes reales)
- Señal RBS antes del inicio



Prokka

Anotación genómica

Anotación funcional

Es el proceso de asignar una función biológica a los genes o proteínas predichas:

- Qué proteína producen
- Qué hace esa proteína (enzima, transporte, defensa, etc.)
- En qué procesos participa



Anotación genómica

Anotación funcional

RBS

delta toxin

```
ACCATTTCGCCCCGGGAGACACGCGGATTACACCTATGAGCAGAAATA
CGGCCTGCGCGATTACCGCGGCGGTGGACGTTCTTCCGCGCGTGAAA
CCGCGATGCGCGTAGCGGCAGGGGGCGATCGCCAAGAAATACTTGGCG
GAAAAGTTCGGCATCGAAATCCGCGGCTGCCTGACCCAGATGGGCGA
CATTCCGCTGGAGATTAAAGACTGGCGTCAGGTTGAGCTTAATCCGT
TCTGGCGGTGGACGTTCTTCCGCGCGTGAAACCGCGATGCGCGTAGC
GGCAGGGGGCGATCGCCAAGAAATACCTGGCGGAAAAGTTCGGCATCG
AAATCCGCGGCTGCCTGACCCAGATGGGCGACATTCCGCTGGAGATT
AAAGACTGGCGTCAGGTTGAGCTTAATCCGTTTTTTTTTGGCC
```

Transfer
RNA

Homopolymer



Anotación genómica

Anotación funcional

Query MKKTAIAIAVALAGFATVAQ

BLASTP

Query	MKKTAIAIAVALAGFATVAQ
Database	MKKTAIAIAVALAGFATVAQ

Anotación genómica

Anotación funcional

Alineamiento múltiple por familia

```
MKKTAIAVAVALAGFATVAQ
MKKTAIAVAVALAGFATVAQ
MKKTAIAVAVALAGYATVAQ
```

HMMER

Probabilidades

aminoácido	probabilidad
F	0.8
Y	0.2


```

0  ##gff-version 3.2.1
1  ##sequence-region ctg123 1 1497228
2  ctg123 . gene          1000  9000  .  +  .  ID=gene00001;Name=EDEN
3  ctg123 . TF_binding_site 1000  1012  .  +  .  ID=tfbs00001;Parent=gene00001
4  ctg123 . mRNA          1050  9000  .  +  .  ID=mRNA00001;Parent=gene00001;Name=EDEN.1
5  ctg123 . mRNA          1050  9000  .  +  .  ID=mRNA00002;Parent=gene00001;Name=EDEN.2
6  ctg123 . mRNA          1300  9000  .  +  .  ID=mRNA00003;Parent=gene00001;Name=EDEN.3
7  ctg123 . exon          1300  1500  .  +  .  ID=exon00001;Parent=mRNA00003
8  ctg123 . exon          1050  1500  .  +  .  ID=exon00002;Parent=mRNA00001,mRNA00002
9  ctg123 . exon          3000  3902  .  +  .  ID=exon00003;Parent=mRNA00001,mRNA00003
10 ctg123 . exon          5000  5500  .  +  .  ID=exon00004;Parent=mRNA00001,mRNA00002,mRNA00003
11 ctg123 . exon          7000  9000  .  +  .  ID=exon00005;Parent=mRNA00001,mRNA00002,mRNA00003
12 ctg123 . CDS           1201  1500  .  +  0  ID=cds00001;Parent=mRNA00001;Name=edenprotein.1
13 ctg123 . CDS           3000  3902  .  +  0  ID=cds00001;Parent=mRNA00001;Name=edenprotein.1
14 ctg123 . CDS           5000  5500  .  +  0  ID=cds00001;Parent=mRNA00001;Name=edenprotein.1
15 ctg123 . CDS           7000  7600  .  +  0  ID=cds00001;Parent=mRNA00001;Name=edenprotein.1
16 ctg123 . CDS           1201  1500  .  +  0  ID=cds00002;Parent=mRNA00002;Name=edenprotein.2
17 ctg123 . CDS           5000  5500  .  +  0  ID=cds00002;Parent=mRNA00002;Name=edenprotein.2
18 ctg123 . CDS           7000  7600  .  +  0  ID=cds00002;Parent=mRNA00002;Name=edenprotein.2
19 ctg123 . CDS           3301  3902  .  +  0  ID=cds00003;Parent=mRNA00003;Name=edenprotein.3
20 ctg123 . CDS           5000  5500  .  +  1  ID=cds00003;Parent=mRNA00003;Name=edenprotein.3
21 ctg123 . CDS           7000  7600  .  +  1  ID=cds00003;Parent=mRNA00003;Name=edenprotein.3
22 ctg123 . CDS           3391  3902  .  +  0  ID=cds00004;Parent=mRNA00003;Name=edenprotein.4
23 ctg123 . CDS           5000  5500  .  +  1  ID=cds00004;Parent=mRNA00003;Name=edenprotein.4
24 ctg123 . CDS           7000  7600  .  +  1  ID=cds00004;Parent=mRNA00003;Name=edenprotein.4



```


Preprocesamiento


Control de calidad

Caracterización


Comparación



Análisis a partir de lecturas



Análisis a partir de ensamblaje de novo





Análisis a partir de ensamblaje de referencia

Preprocesamiento


Control de calidad

Caracterización


Comparación



Análisis a partir de lecturas




Análisis a partir de ensamblaje de novo



Análisis a partir de ensamblaje de referencia

Roary


Pangenoma



Conjunto total de genes
que se encuentran en
todas las cepas de una
misma especie bacteriana

Roary


Genoma central



Genes que comparten
todas las cepas

Relacionados con
funciones básicas
esenciales

Genoma accesorio




Genes presentes en algunas, pero no todas, las cepas

Brindan ventajas adaptativas, como resistencia a antibióticos

Roary

Genes únicos



Genes exclusivos de una sola cepa

Asociados a adaptaciones muy específicas



Roary

Pangenoma

Extracción de proteínas

Genoma A geneA1, geneB1, geneC1

Genoma B geneA2, geneB2, geneD1

Genoma C geneA3, geneB3, geneE1



Pangenoma

Genoma	Proteínas
A	geneA1, geneB1, geneC1
B	geneA2, geneB2, geneD1
C	geneA3, geneB3, geneE1

Extracción de proteínas



Roary

Pangenoma

**Agrupación por clúster
CD-HIT**

geneA1 $\approx$ geneA2 $\approx$ geneA3

Clúster temporal 1

geneB1 $\approx$ geneB2 $\approx$ geneB3

Clúster temporal 2



Roary

Pangenoma

BLAST


geneA1	MKKTAIAIAVALAGFATVAQ
geneA2	MKKTAIAIAVALAGFATVAQ

% identidad
95%

e-value
1e-50

Pangenoma

grafo de similitud



Markov Clustering (MCL)

Clúster 1

geneA1, geneA2, geneA3

Clúster 2

geneB1, geneB2



Pangenoma

Construcción de la matriz
presencia/ausencia

Clúster	Genoma A	Genoma B	Genoma C
Cluster1	1	1	1
Cluster2	1	1	1
Cluster3	1	0	0
Cluster4	0	1	0
Cluster5	0	0	1



Pangenoma

Definición del pangenoma

Clúster	Genoma A	Genoma B	Genoma C
Cluster1	1	1	1
Cluster2	1	1	1
Cluster3	1	0	0
Cluster4	0	1	0
Cluster5	0	0	1



Roary

Pangenoma

Definición del pangenoma

Core genome (genes presentes en todos los genomas)

Cluster1, Cluster2: geneA y geneB

Accessory genome (presentes en algunos genomas)



Cluster3, Cluster4, Cluster5: geneC, geneD, geneE

Preprocesamiento


Control de calidad

Caracterización


Comparación



Análisis a partir de lecturas



Análisis a partir de ensamblaje de novo





Análisis a partir de ensamblaje de referencia

Preprocesamiento


Control de calidad

Caracterización


Comparación



Análisis a partir de lecturas



Análisis a partir de ensamblaje de novo



Análisis a partir de ensamblaje de referencia

SNP-sites



core alignment

```
ATGCTAGCTAGCTAGC
ATGCTTGCTAGCTAGC
ATGCTAGCTAGCTTGC
```

SNP-sites



core alignment

>g1

ATGCTA

>g2

ATGCTT

>g3

ATGCTA



Columna por columna

core alignment

>g1

ATGCTA

>g2

ATGCTT

>g3

ATGCTA



core alignment

```
>g1
ATGCTA
>g2
ATGCTT
>g3
ATGCTA
```

Columna por columna
Columna 1

g1: A
g2: A
g3: A

si tamaño del conjunto = 1
No SNP

{A,} → tamaño = 1



core alignment

```
>g1
ATGCTA
>g2
ATGCTT
>g3
ATGCTA
```

Columna por columna
Columna 6

g1: A
g2: T
g3: A

si tamaño del conjunto > 1
SNP



Si una columna es SNP:

- Se guarda su posición
- Se agrega al nuevo alineamiento



Si una columna es SNP:

- Se guarda su posición
- Se agrega al nuevo alineamiento

Entrada

ATGCTA
ATGCTT
ATGCTA

Salida



A
T
A

Preprocesamiento


Control de calidad

Caracterización


Comparación



Análisis a partir de lecturas



Análisis a partir de ensamblaje de novo





Análisis a partir de ensamblaje de referencia

Preprocesamiento


Control de calidad

Caracterización


Comparación



Análisis a partir de lecturas



Análisis a partir de ensamblaje de novo



Análisis a partir de ensamblaje de referencia



Maximum likelihood (ML)

1. Se propone un árbol filogenético (una hipótesis).
2. Se asume un modelo de evolución (cómo cambian las secuencias).
3. Se calcula la probabilidad de observar los datos reales bajo ese árbol y ese modelo.
4. Se repite con muchos árboles posibles.
5. Se elige el árbol con la mayor probabilidad (likelihood).

IQ-TREE 2



Maximum likelihood (ML)

Alineamiento

A: AT

B: AT

C: TT

D: TA



Maximum likelihood (ML)

Alineamiento

A: AT

B: AT

C: TT

D: TA

Propone árboles candidatos

Tree1: ((A,B),(C,D))

Tree2: ((A,C),(B,D))

Tree3: ((A,D),(B,C))

Maximum likelihood (ML)

Alineamiento

A: AT

B: AT

C: TT

D: TA

Evaluar cada árbol (Maximum Likelihood)

Posición 1

A: A

B: A

C: T

D: T



Maximum likelihood (ML)

Alineamiento

A: AT

B: AT

C: TT

D: TA

Evaluar cada árbol (Maximum Likelihood)

Posición 1

A: A

B: A

C: T

D: T

A y B iguales

C y D iguales



Maximum likelihood (ML)

Alineamiento

A: AT

B: AT

C: TT

D: TA

Evaluar cada árbol (Maximum Likelihood)

Tree1: ((A,B),(C,D))

A y B vienen de un ancestro común
(sin cambio)

C y D vienen de otro (sin cambio)

Solo 1 cambio entre grupos



Maximum likelihood (ML)

Alineamiento

A: AT

B: AT

C: TT

D: TA

Muy probable

Evaluar cada árbol (Maximum Likelihood)

Tree1: ((A,B),(C,D))

A y B vienen de un ancestro común
(sin cambio)

C y D vienen de otro (sin cambio)

Solo 1 cambio entre grupos



Maximum likelihood (ML)

Alineamiento

A: AT

B: AT

C: TT

D: TA

Menos probable

Evaluar cada árbol (Maximum Likelihood)

Tree2: ((A,C),(B,D))

A vs C son diferentes

B vs D son diferentes

Necesita más cambios



Maximum likelihood (ML)

Alineamiento

A: AT

B: AT

C: TT

D: TA

Menos probable

Evaluar cada árbol (Maximum Likelihood)

Tree3: ((A,D),(B,C))

A vs D son diferentes

B vs C son diferentes

Necesita más cambios



Maximum likelihood (ML)

Alineamiento

A: AT

B: AT


C: TT

D: TA

Selección del mejor árbol

Tree1: ((A,B),(C,D))

IQ-TREE 2





Preprocesamiento


Control de calidad

Caracterización


Comparación



Análisis a partir de lecturas






Análisis a partir de ensamblaje de novo




Análisis a partir de ensamblaje de referencia


Preprocesamiento



Análisis a partir de lecturas



Análisis a partir de ensamblaje de novo



Análisis a partir de ensamblaje de referencia



Calcula la distancia genética entre pares de secuencias

Alineamiento

>g1

AT

>g2

TT

>g3

AT



Calcula la distancia genética entre pares de secuencias

Alineamiento

```
>g1  
AT  
  
>g2  
TT  
  
>g3  
AT
```

Comparación g1 vs g2

```
g1: A T  
g2: T T
```




Calcula la distancia genética entre pares de secuencias

Alineamiento

>g1

AT

>g2

TT

>g3

AT

Comparación g1 vs g2

g1: A T

g2: T T

Posición 1

Diferentes



Calcula la distancia genética entre pares de secuencias

Alineamiento

>g1

AT

>g2

TT

>g3

AT

Comparación g1 vs g2

g1: A T

g2: T T

Posición 1

Posición 2

Diferentes

Iguales

SNP-dists



Calcula la distancia genética entre pares de secuencias

Alineamiento

>g1

AT

>g2

TT

>g3

AT

Comparación g1 vs g2

g1: A T

g2: T T

Posición 1

Posición 2

Diferentes

Iguales

Distancia
1 SNP



Calcula la distancia genética entre pares de secuencias

Alineamiento

>g1

AT

>g2

TT

>g3

AT

Comparación g1 vs g3

g1: A T

g3: A T

Distancia

0 SNP



Calcula la distancia genética entre pares de secuencias

Alineamiento

```
>g1  
AT  
  
>g2  
TT  
  
>g3  
AT
```

Comparación g2 vs g3

```
g2: T T  
g3: A T
```

Distancia
1 SNP

SNP-dists



Matriz de distancias

	g1	g2	g3
g1	0	1	0
g2	1	0	1
g3	0	1	0

Capacitación de secuenciación genómica y análisis bioinformático

Herramientas de comparación genómica

MSc. Melany Calderón Osorno

mcaldersono@inciensa.sa.cr

Laboratorio de genómica y biología molecular

Junio, 2026